Digitale Edition – Vertiefung und Nutzung

X-Technologien

Marcel Schaeben, Sebastian Zimmer

Programm

Mo

14:00 – 15:30 | XPath vertieft
Einführung / Wiederholung XML-Dokumentstruktur / oXygen
XPath / Prädikate / Operatoren / Funktionen

16:00 – 17:30 | Reguläre Ausdrücke
Analyse und Manipulation von Zeichenketten

Di

09:00 – 10:30 | Basistechnologien für Auswertungsdaten I
Grundlagen Transformation von XML-Dokumenten mit XSLT

11:00 – 12:30 | Basistechnologien für Auswertungsdaten II
XSLT vertieft / Erweiterte Sprachkonstrukte / Sortierung / Ausgabeformate

14:00 – 15:30 | Auswertungen
XSL-Transformation nach CSV / Datenaufbereitung zur Anzeige im DARIAH-Geobrowser

XPath vertieft – Übersicht

- Wiederholung: XML-Dokumentbaum
- XPath-Grundlagen
- XPath in oXygen
- Prädikate
- Operatoren
- Funktionen

XPath?

/TEI//div/lg[count(./l) > 2]

- „Xpath is a language for **addressing** parts of an XML document“ (W3C XPath Spezifikation) – https://www.w3.org/TR/xpath-31/

- Navigation in XML-Dokumenten
  - Vergleiche: Dateipfade – C:\Dokumente\Workshop\Folien.pptx
- Erzeugung von Rückgaben: Sequenzen (Mengen) von
  - Elementen
  - Zeichenketten (Strings)
  - Zahlen
  - Wahrheitswerten
- Fragen an das Dokument stellen

Wiederholung: XML-Dokumentstruktur

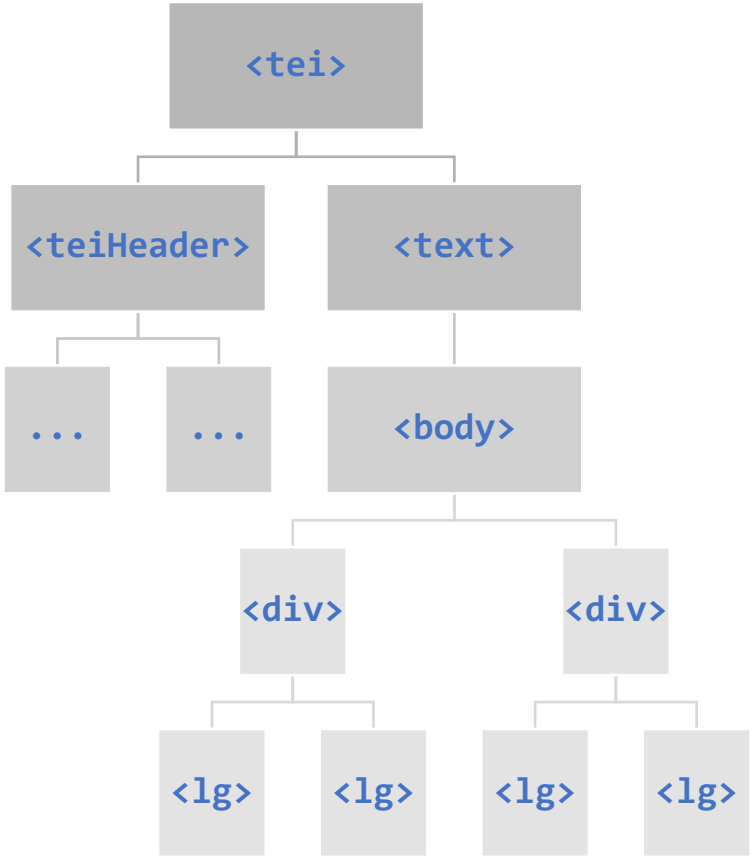

Wiederholung: XML-Dokumentstruktur

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>...</teiHeader>
 <text>
   <body>
     <div type="sonnet">
       <head>Sonnet 18</head>
       <lg type="quatrain">
         <l n="1">Shall I compare thee to a summer's day?</l>
         <l n="2">Thou art more lovely and more temperate:</l>
        ...
       </lg>
       ...
       <lg type = "couplet">
         <l n="13">So long as men can breathe or eyes can see,</l>
         <l n="14">So long lives this and this gives life to thee. </l>
       </lg>
     </div>
   </body>
 </text>
</TEI>
```

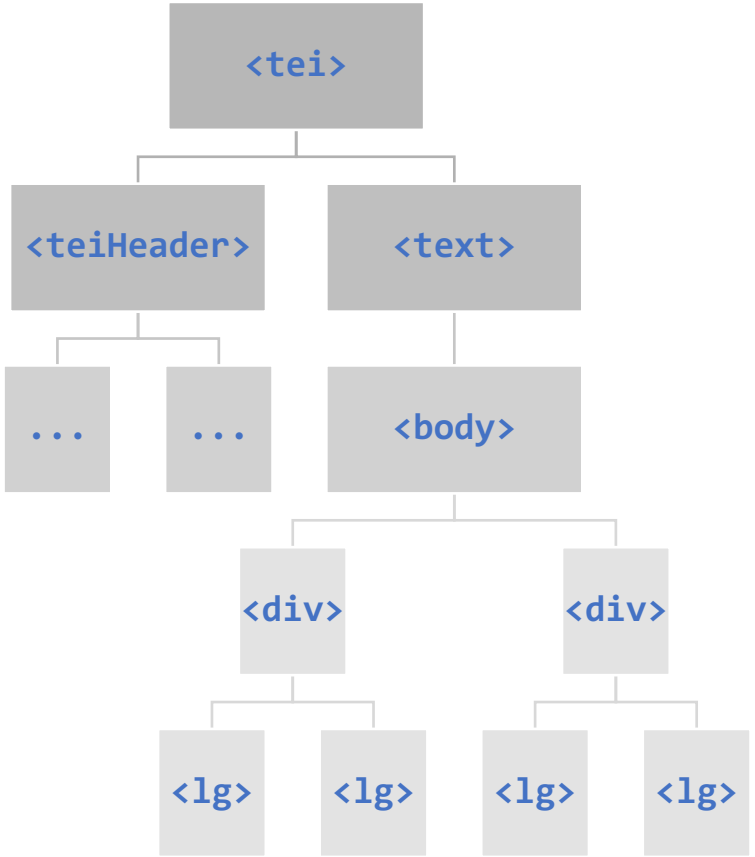

Knotenarten

```
<?xml version="1.0" encoding="UTF-8"?>
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>...</teiHeader>
 <text>
   <body>
    <div type="sonnet">
     <head>Sonnet 18</head>
     <lg type="quatrain">
      <l n="1">Shall I compare thee to a summer's day?</l>
      <l n="2">Thou art more lovely and more temperate:</l>
      <!-- TODO: hier fehlen Zeilen, bitte ergänzen -->
     </lg>
     ...
     <lg type = "couplet">
      <l n="13">So long as men can breathe or eyes can see,</l>
      <l n="14">So long lives this and this gives life to thee. </l>
     </lg>
    </div>
   </body>
 </text>
</TEI>
```

Dokumentknoten

„Unsichtbarer“ Knoten, der das gesamte Dokument umfasst

Knotenarten

```
<?xml version="1.0" encoding="UTF-8"?>
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>...</teiHeader>
 <text>
  <body>
   <div type="sonnet">
    <head>Sonnet 18</head>
    <lg type="quatrain">
     <l n="1">Shall I compare thee to a summer's day?</l>
     <l n="2">Thou art more lovely and more temperate:</l>
     <!-- TODO: hier fehlen Zeilen, bitte ergänzen -->
    </lg>
    ...
    <lg type = "couplet">
     <l n="13">So long as men can breathe or eyes can see,</l>
     <l n="14">So long lives this and this gives life to thee. </l>
    </lg>
   </div>
  </body>
 </text>
</TEI>
```

Wurzelknoten

Der erste (und einzige) Elementknoten im Dokument

- Kind des Dokumentknotens
- Vorfahre aller weiteren Elementknoten im Dokument

Knotenarten

```
<?xml version="1.0" encoding="UTF-8"?>
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>...</teiHeader>
 <text>
  <body>
   <div type="sonnet">
    <head>Sonnet 18</head>
    <lg type="quatrain">
     <l n="1">Shall I compare thee to a summer's day?</l>
     <l n="2">Thou art more lovely and more temperate:</l>
     <!-- TODO: hier fehlen Zeilen, bitte ergänzen -->
    </lg>
    ...
    <lg type = "couplet">
     <l n="13">So long as men can breathe or eyes can see,</l>
     <l n="14">So long lives this and this gives life to thee. </l>
    </lg>
   </div>
  </body>
 </text>
</TEI>
```

Elementknoten

<elementname>

...

</elementname>

Knotenarten

```
<?xml version="1.0" encoding="UTF-8"?>
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>...</teiHeader>
 <text>
   <body>
    <div type="sonnet">
     <head>Sonnet 18</head>
     <lg type="quatrain">
      <l n="1">Shall I compare thee to a summer's day?</l>
      <l n="2">Thou art more lovely and more temperate:</l>
      <!-- TODO: hier fehlen Zeilen, bitte ergänzen -->
     </lg>
     ...
     <lg type = "couplet">
      <l n="13">So long as men can breathe or eyes can see,</l>
      <l n="14">So long lives this and this gives life to thee. </l>
     </lg>
    </div>
   </body>
 </text>
</TEI>
```

Attributknoten

attribut="wert"

Knotenarten

```
<?xml version="1.0" encoding="UTF-8"?>
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>...</teiHeader>
 <text>
   <body>
    <div type="sonnet">
     <head>Sonnet 18</head>
     <lg type="quatrain">
      <l n="1">Shall I compare thee to a summer's day?</l>
      <l n="2">Thou art more lovely and more temperate:</l>
      <!-- TODO: hier fehlen Zeilen, bitte ergänzen -->
     </lg>
     ...
     <lg type = "couplet">
      <l n="13">So long as men can breathe or eyes can see,</l>
      <l n="14">So long lives this and this gives life to thee.</l>
     </lg>
    </div>
   </body>
 </text>
</TEI>
```

Textknoten

Knotenarten

```
<?xml version="1.0" encoding="UTF-8"?>
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>...</teiHeader>
 <text>
   <body>
    <div type="sonnet">
     <head>Sonnet 18</head>
     <lg type="quatrain">
      <l n="1">Shall I compare thee to a summer's day?</l>
      <l n="2">Thou art more lovely and more temperate:</l>
      <!-- TODO: hier fehlen Zeilen, bitte ergänzen -->
     </lg>
     ...
     <lg type = "couplet">
      <l n="13">So long as men can breathe or eyes can see,</l>
      <l n="14">So long lives this and this gives life to thee. </l>
     </lg>
    </div>
   </body>
 </text>
</TEI>
```

Kommentarknoten

<!-- Kommentar -->

Knotenarten

```
<?xml version="1.0" encoding="UTF-8"?>
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>...</teiHeader>
 <text>
   <body>
    <div type="sonnet">
     <head>Sonnet 18</head>
     <lg type="quatrain">
      <l n="1">Shall I compare thee to a summer's day?</l>
      <l n="2">Thou art more lovely and more temperate:</l>
      <!-- TODO: hier fehlen Zeilen, bitte ergänzen -->
     </lg>
     ...
     <lg type = "couplet">
      <l n="13">So long as men can breathe or eyes can see,</l>
      <l n="14">So long lives this and this gives life to thee. </l>
     </lg>
    </div>
   </body>
 </text>
</TEI>
```

Verarbeitungsanweisungen

<? ... ?>

Element-, Attribut- und Textknoten

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>...</teiHeader>
 <text>
   <body>
     <div type="sonnet">
       <head>Sonnet 18</head>
       <lg type="couplet">
         <l n="1">So long as men...</l>
         <l n="2">So long lives ...</l>
       </lg>
     </div>
   </body>
 </text>
</TEI>
```

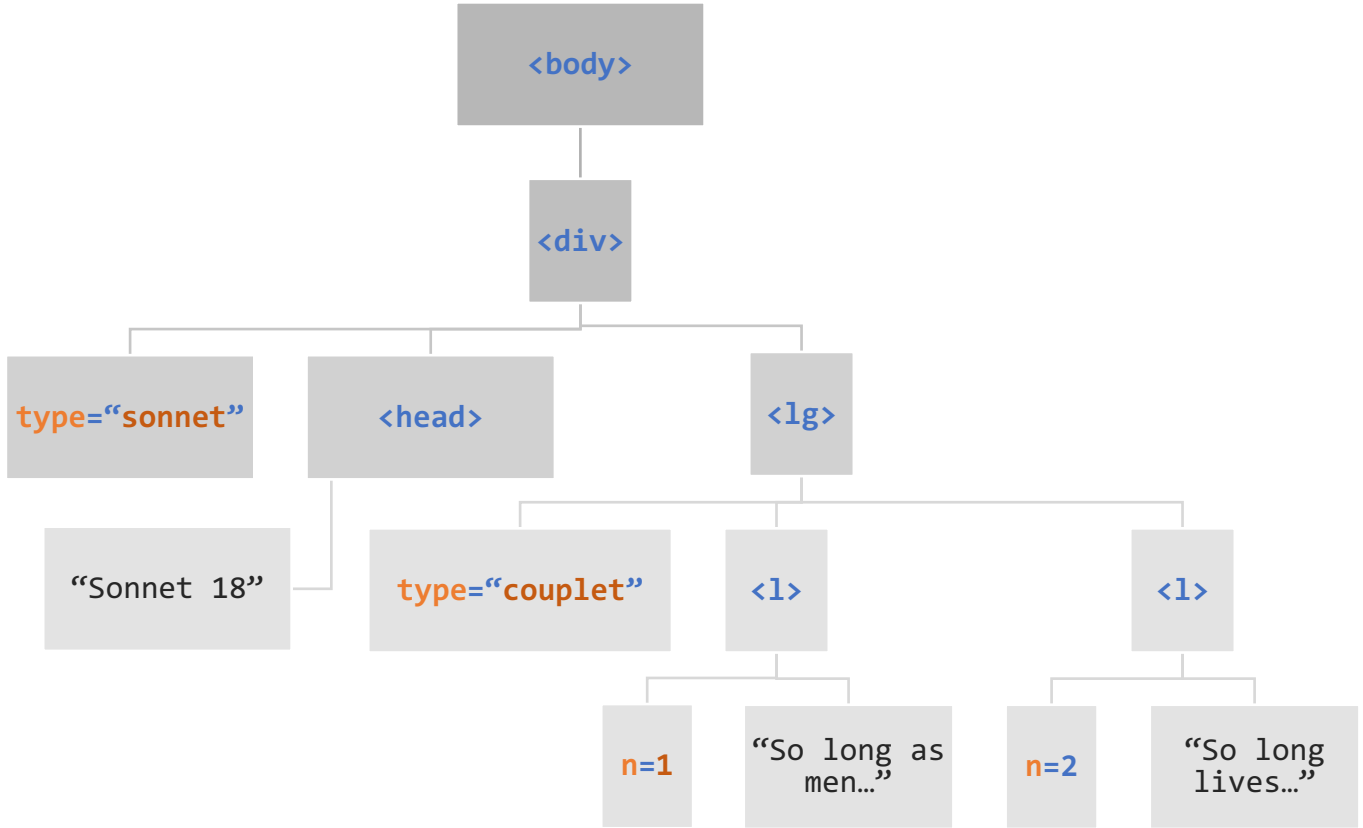

Bewegung im Baum

/TEI/text//lg/l

- Schrittweise Bewegung im Baum durch XPath-Ausdrücke
- Schritte im Pfad werden durch „/“ getrennt
- XML-Verarbeitung beginnt am Dokument-Knoten
- XPath-Schritte haben eine Richtung, die sog. „Achse“

Achsen: „Familienverhältnisse“

- Selbst
  `self`
- Eltern / Kind
  `parent / child`
- Vorfahren / Nachfahren
  `ancestor / descendant`

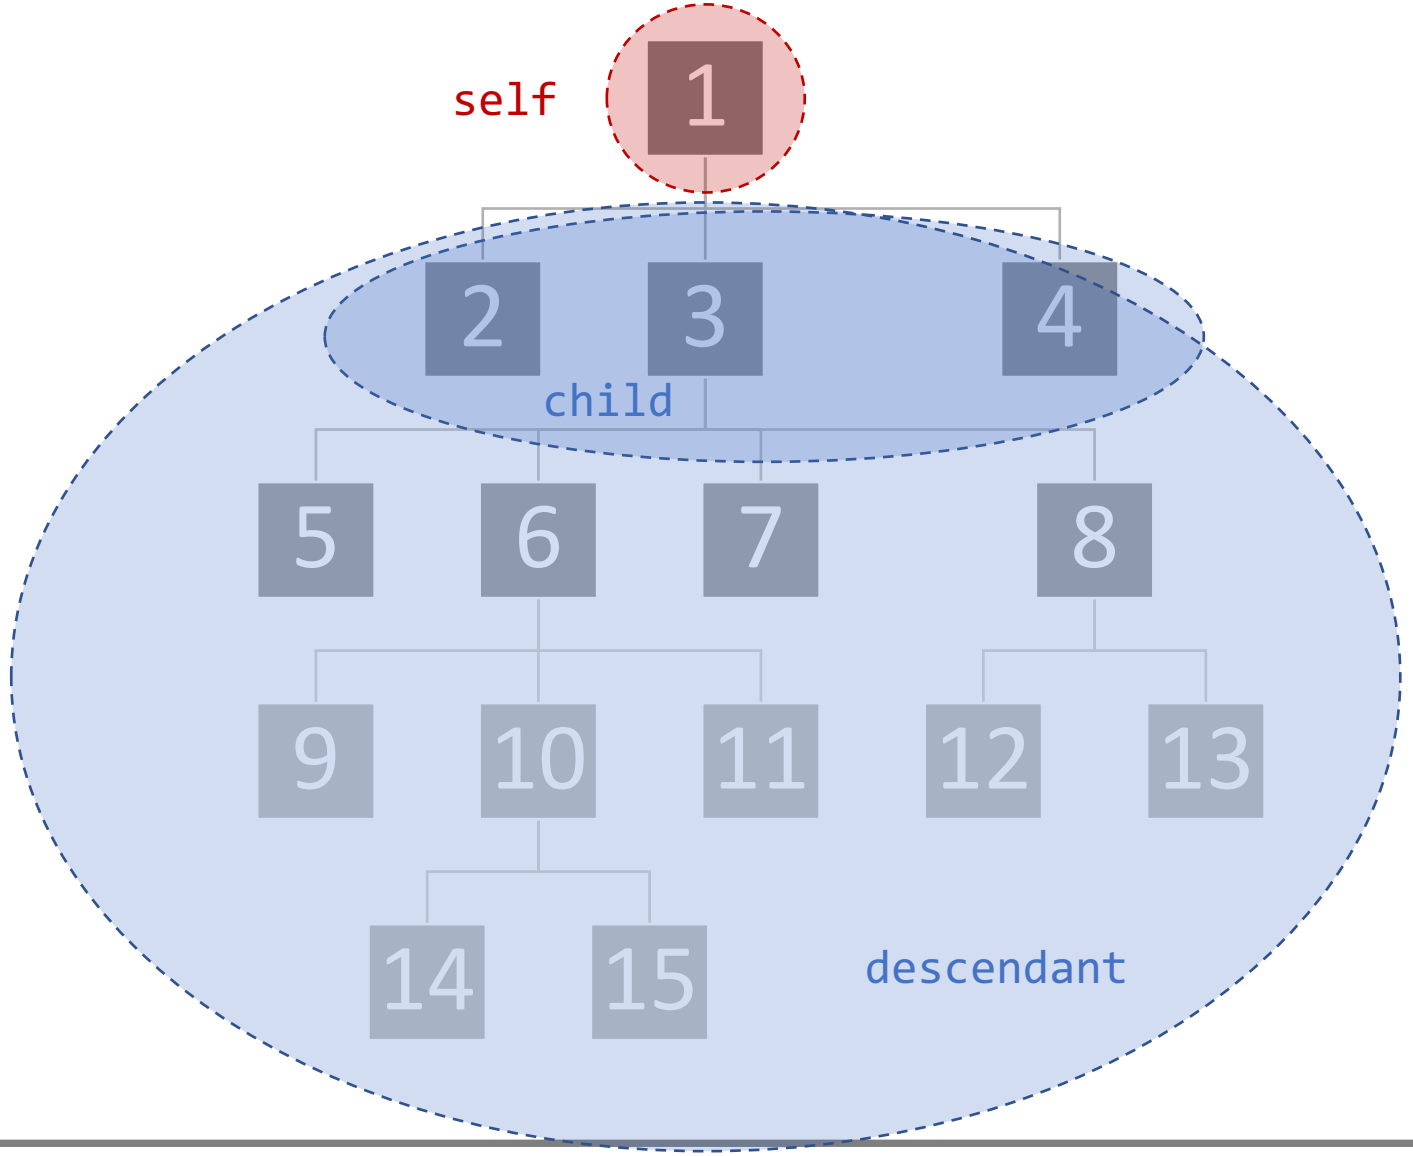

Achsen: „Familienverhältnisse“

- Selbst
  `self`
- Eltern / Kind
  `parent / child`
- Vorfahren / Nachfahren
  `ancestor`
  `descendant`
- Geschwister
  `preceding-sibling`
  `following-sibling`

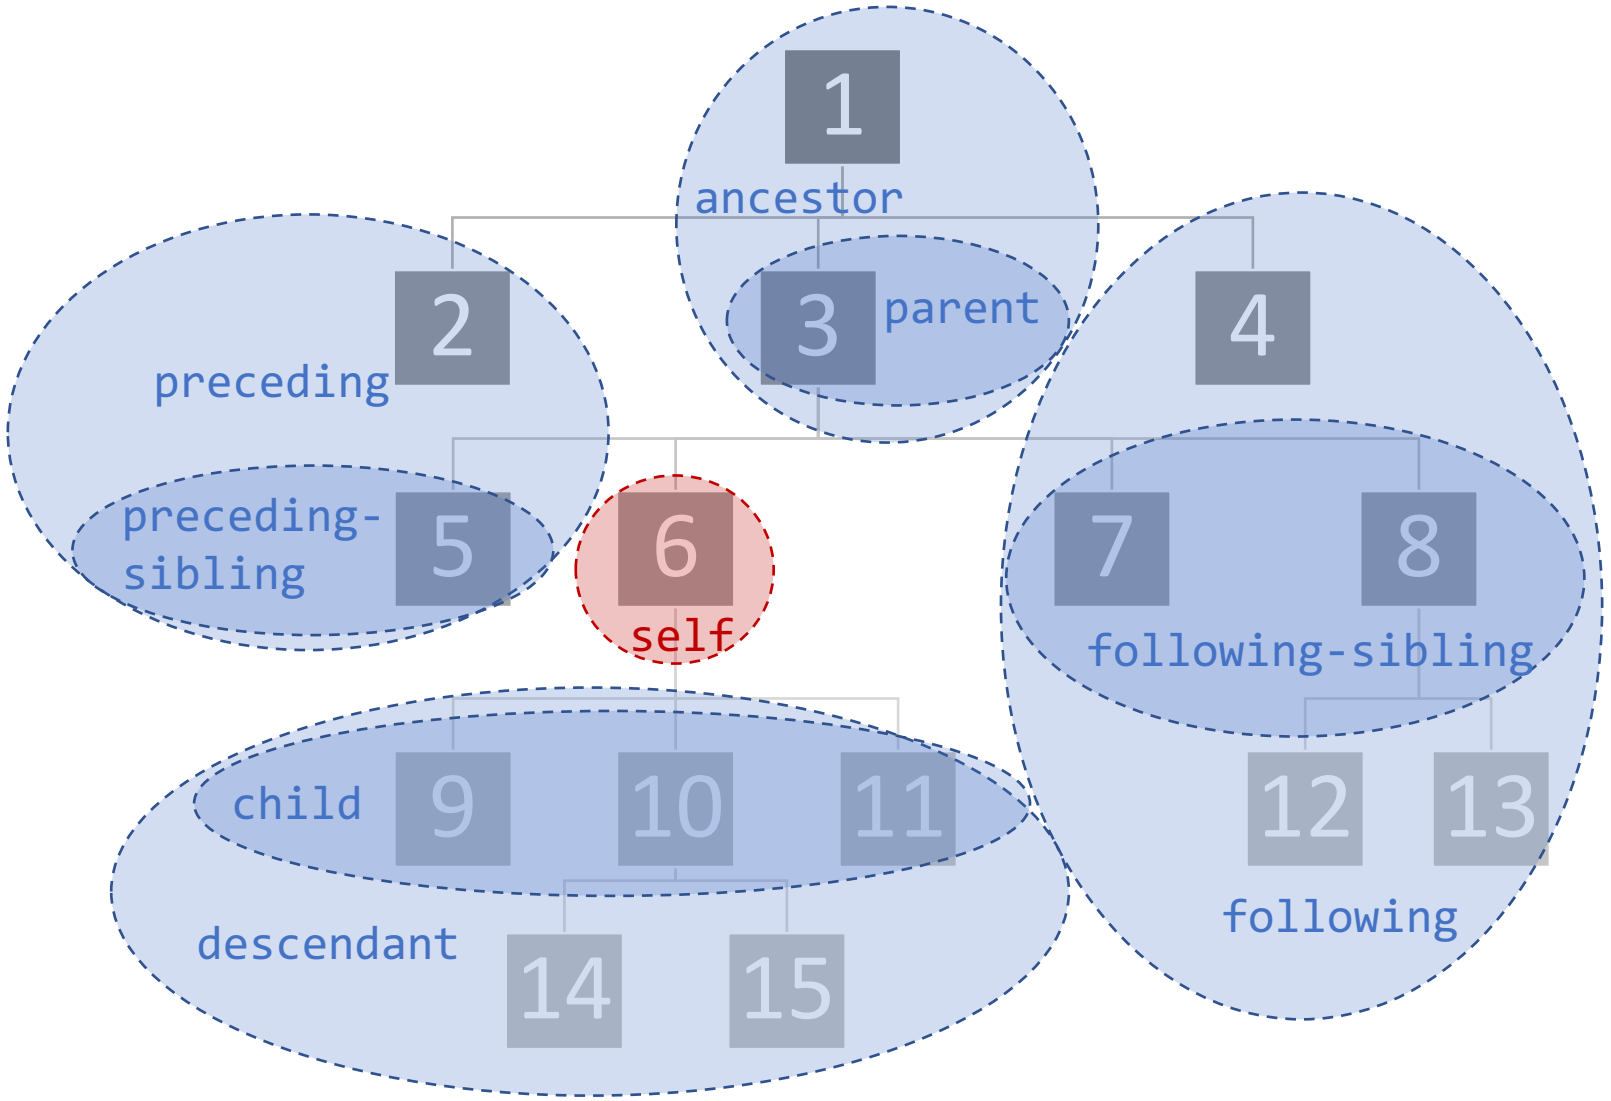

XPath-Syntax: Lokalisierungsschritte

- Aneinanderreihung von Schritten der Form

  achse::knotentest[Prädikat]

  getrennt durch „/“

- Beispiel

/child::TEI/child::text/descendant-or-self::l
/descendant-or-self::l/attribute::n

XPath-Achsen
self::
child::
descendant:: descendant-or-self::
preceding-sibling::
preceding::
following-sibling::
following::
parent::
ancestor::
attribute::

XPath-Syntax: Lokalisierungsschritte

„gehe von hier nach da“

/child::TEI/child::text/descendant-or-self::l

⟺ /TEI/text//l

/descendant-or-self::l/attribute::n

⟺ //l/@n

XPath-Achsen	Kurzform
self::	.
child::	/
descendant:: descendant-or-self::	//
preceding-sibling::	
preceding::	
following-sibling::	
following::	
parent::	..
ancestor::	
attribute::	@

XPath-Syntax: Knotentests

„bist du der, den ich suche?“

/child::TEI/child::text/descendant-or-self::l

⟺ /TEI/text//l

/descendant-or-self::l/attribute::n

⟺ //l/@n

Knotentest	Beschreibung
`xyz`	Elementknoten mit dem Namen „xyz“
`@xyz`	Attributknoten mit dem Namen „xyz“
`*`	Jeder Elementknoten
`@*`	Jeder Attributknoten
`node()`	Jeder Knoten beliebigen Typs
`text()`	Nur Textknoten
`comment()`	Nur Kommentarknoten: <!-- xyz -->
`processing-instruction()`	Verarbeitungsanweisungen <?name wert ?>

Beispiele: Einfache Ausdrücke

```
/TEI/text/body/div/head
//body/div/head
```

XPath-Achsen	Kurzform
child::	/
descendant-or-self::	//

Knotentest	Beschreibung
xyz	Elementknoten mit dem Namen „xyz“

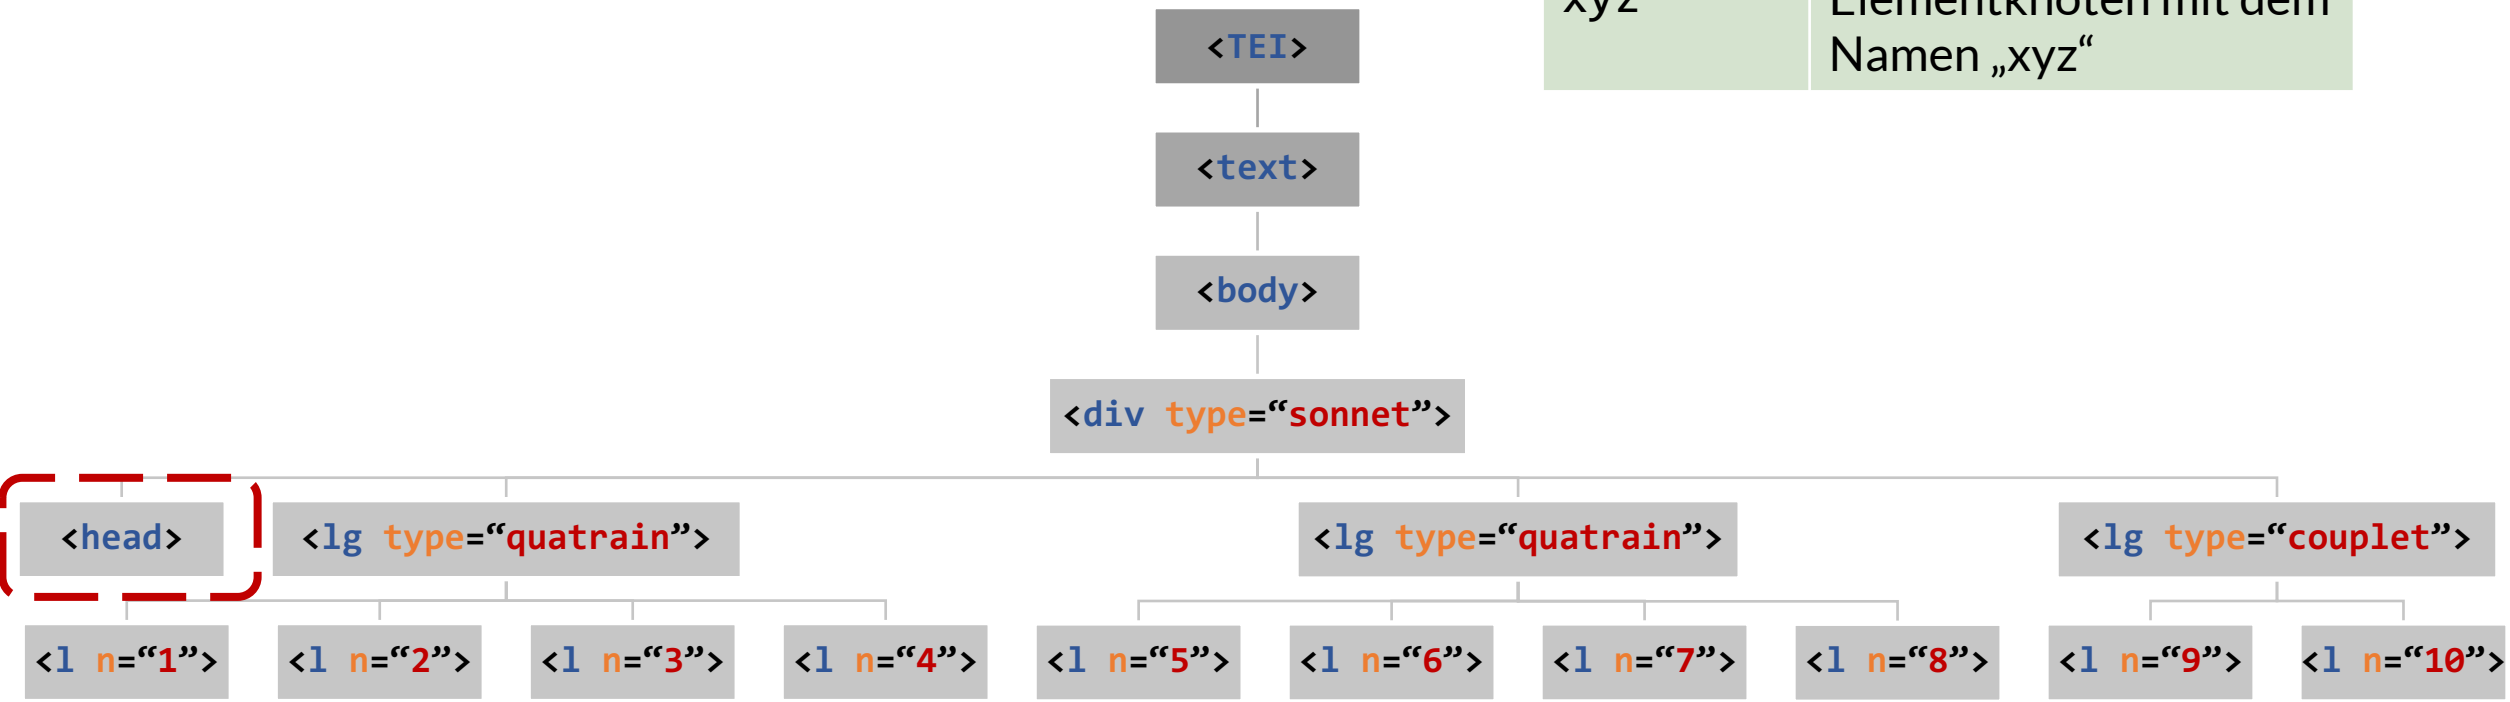

Beispiele: Einfache Ausdrücke

```
//body/div/lg/@type
```

XPath-Achsen	Kurzform
child::	/
descendant-or-self::	//

Knotentest	Beschreibung
xyz	Elementknoten mit dem Namen „xyz“
@xyz	Attributknoten mit dem Namen „xyz“

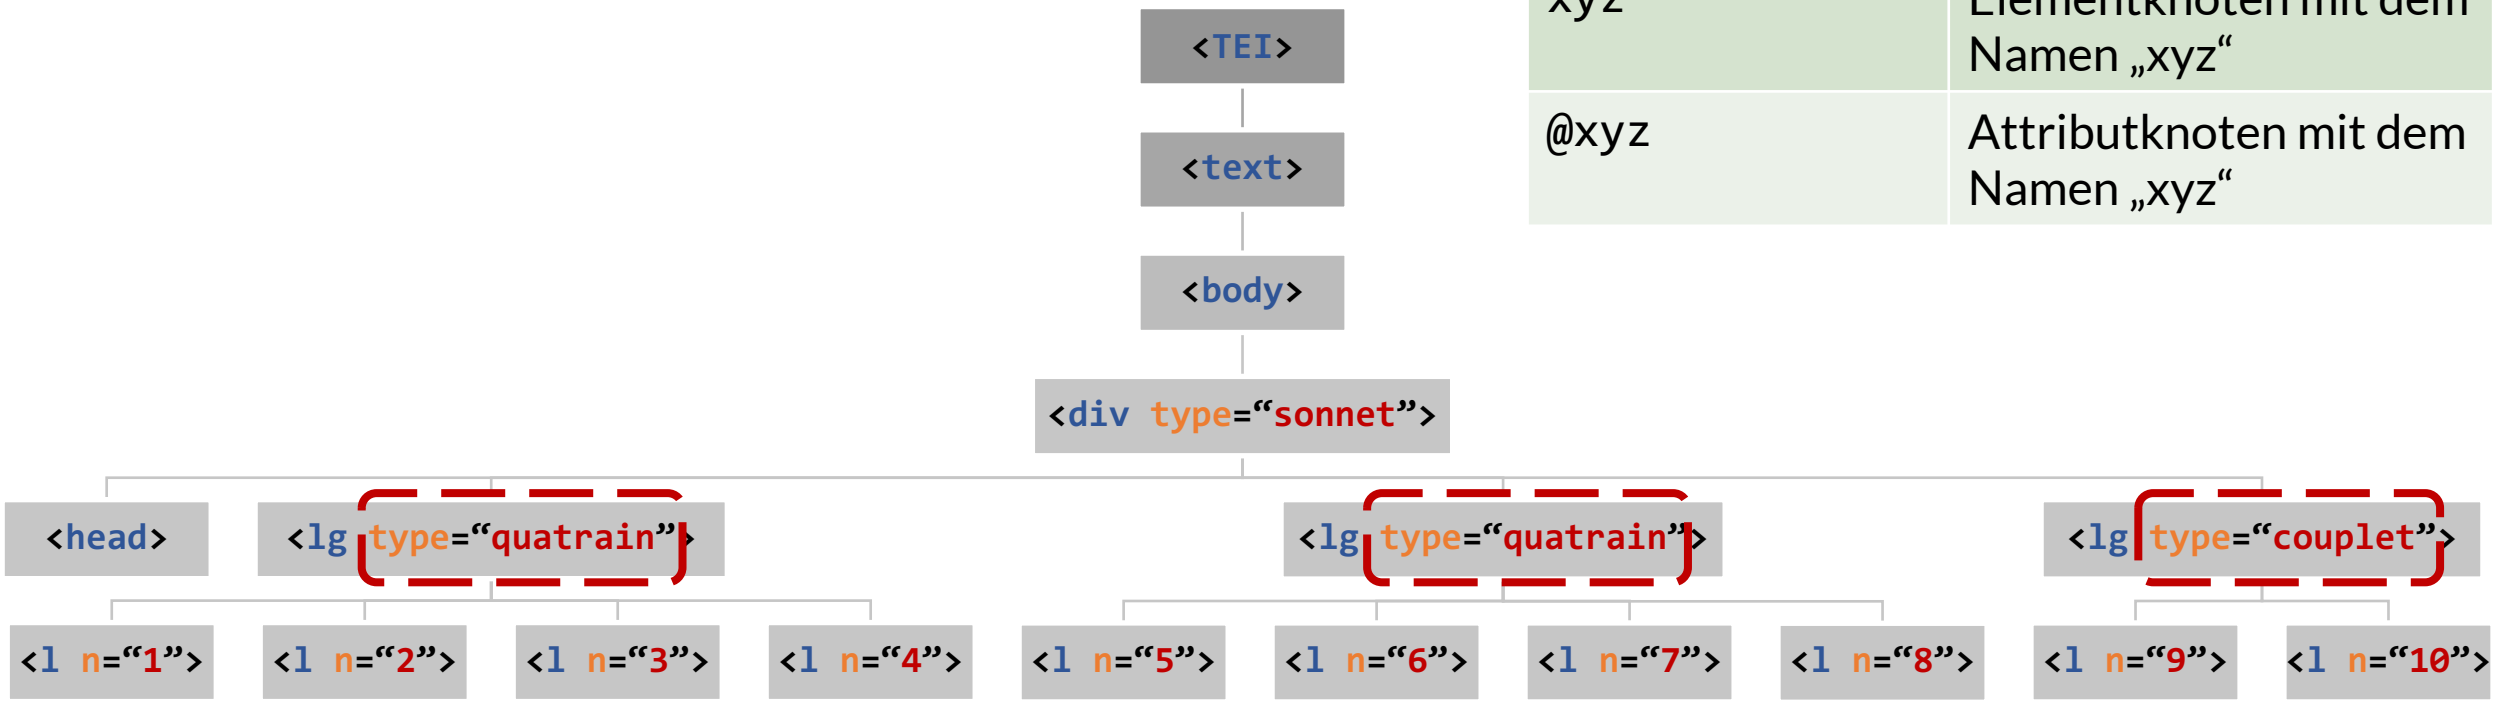

Übung: Einfache Ausdrücke

- Öffnen Sie die Datei *beispiel1.xml* in Oxygen
- Finden Sie alle `lg`-Elemente, die vom `div`-Element abstammen
- Finden Sie den *Parent* des `head`-Elements
- Finden Sie alle `l`-Elemente
- Probieren Sie weitere einfache XPath-Ausdrücke aus

XPath-Achsen	Kurzform
`child::`	`/`
`descendant-or-self::`	`//`
`parent::`	`..`

Knotentest	Beschreibung
`xyz`	Elementknoten mit dem Namen „xyz“
`@xyz`	Attributknoten mit dem Namen „xyz“

XPath-Syntax: Prädikate

Bedingungen, welche die Kontextsequenz weiter einschränken

„finde alle vierzeiligen Verse“

→ „finde alle lg-Elemente vom typ ‚quatrain‘“

/TEI/text//lg[@type=“quatrain“]

„finde alle Verse, die Zeilen enthalten“

→ „finde alle lg-Elemente, die l-Elemente enthalten“

/TEI/text//lg[l]

Operator	Beschreibung
=	Gleichheit
!=	Ungleicheit
gt oder > ge oder >=	Größer als Größer als oder gleich
lt oder < le oder <=	Kleiner als Kleiner als oder gleich
+ - * div	Addition, Subtraktion, Muliplikaiton, Division
and	Verknüpfung mit „UND“
or	Verknüpfung mit „ODER“

XPath-Syntax: Prädikate

Prädikate können kombiniert und verschachtelt werden

„finde alle lg-Elemente vom typ ‚quatrain', die l-Elemente enthalten"

```
/TEI/text//lg[@type="quatrain"][l]
/TEI/text//lg[@type="quatrain" and l]
```

„finde alle div-Elemente, die mind. ein lg-Element vom typ ‚couplet' enthalten"

```
//div[ lg[ @type="couplet"] ]
```

Operator	Beschreibung
=	Gleichheit
!=	Ungleicheit
gt oder > ge oder >=	Größer als Größer als oder gleich
lt oder < le oder <=	Kleiner als Kleiner als oder gleich
+ - * div	Addition, Subtraktion, Muliplikaiton, Division
and	Verknüpfung mit „UND"
or	Verknüpfung mit „ODER"

Beispiele: Ausdrücke mit Prädikaten

```
//body/div/lg[@type="quatrain"]
```

XPath-Achsen	Kurzform
child::	/
descendant-or-self::	//

Knotentest	Beschreibung
xyz	Elementknoten mit dem Namen „xyz“
@xyz	Attributknoten mit dem Namen „xyz“

Operator	Beschreibung
=	Gleichheit

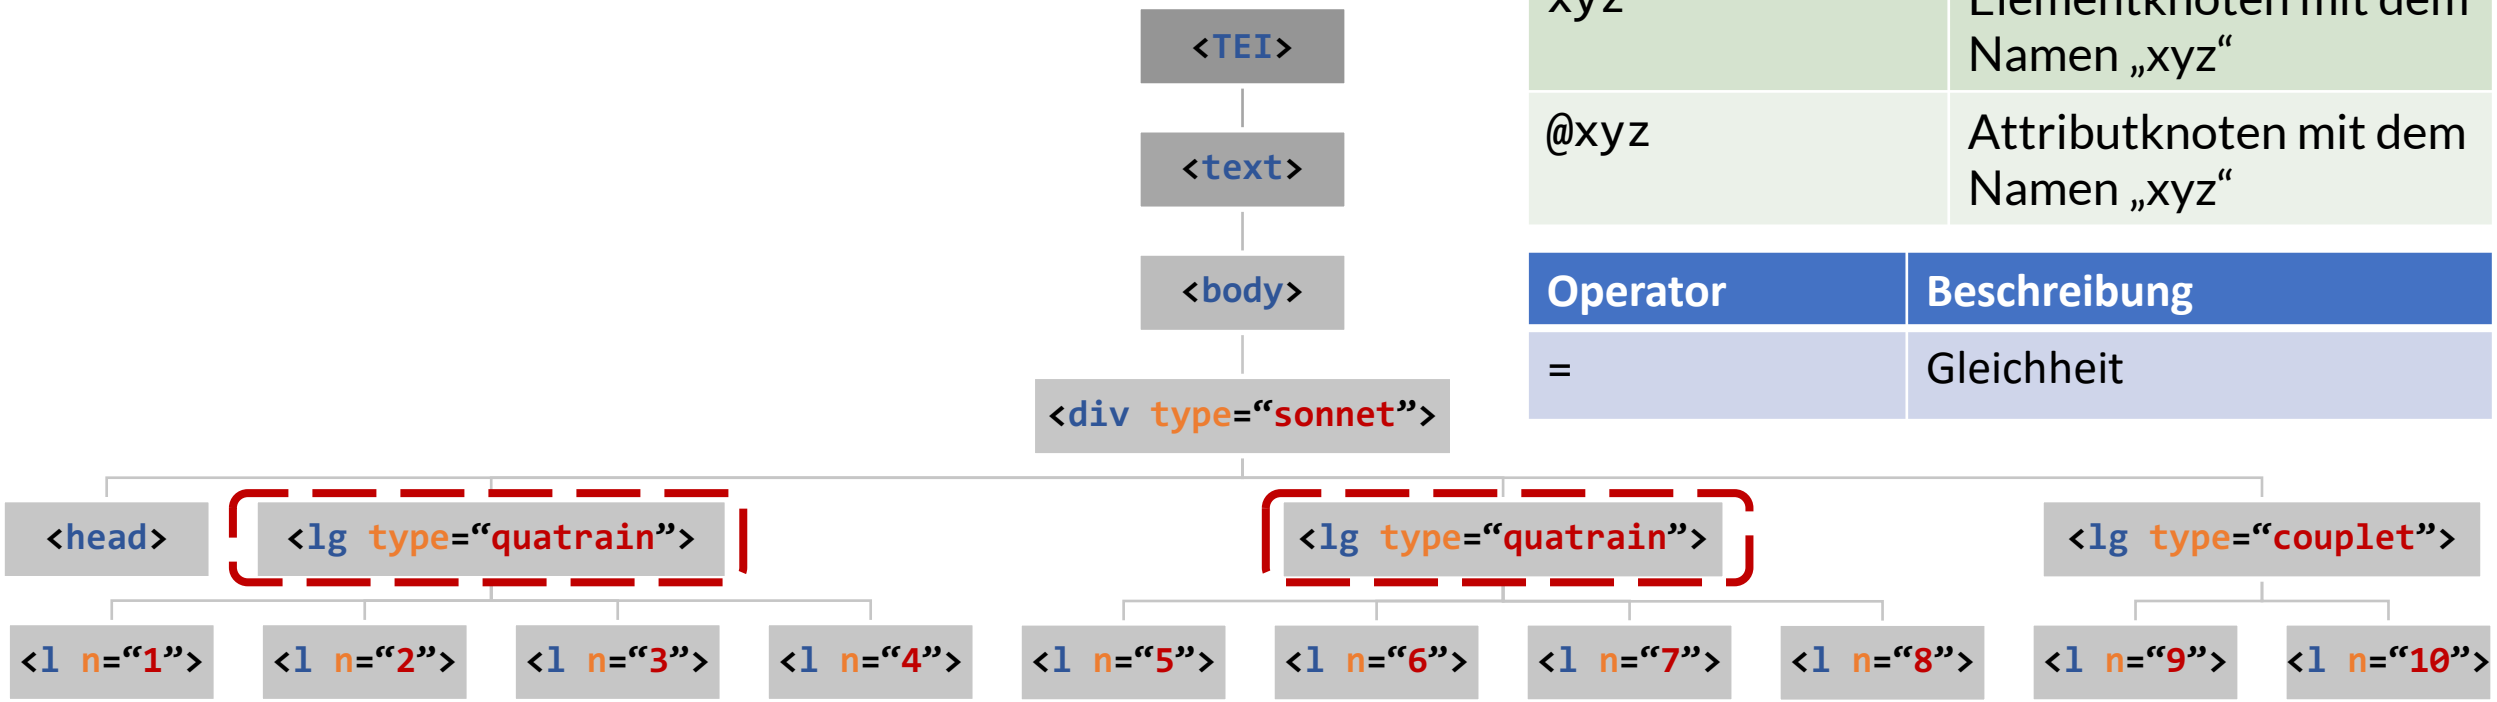

Beispiele: Ausdrücke mit Prädikaten

```
//body/div/lg/l[@n > 2]
```

XPath-Achsen	Kurzform
child::	/
descendant-or-self::	//

Knotentest	Beschreibung
xyz	Elementknoten mit dem Namen „xyz“
@xyz	Attributknoten mit dem Namen „xyz“

Operator	Beschreibung
>	Größer als

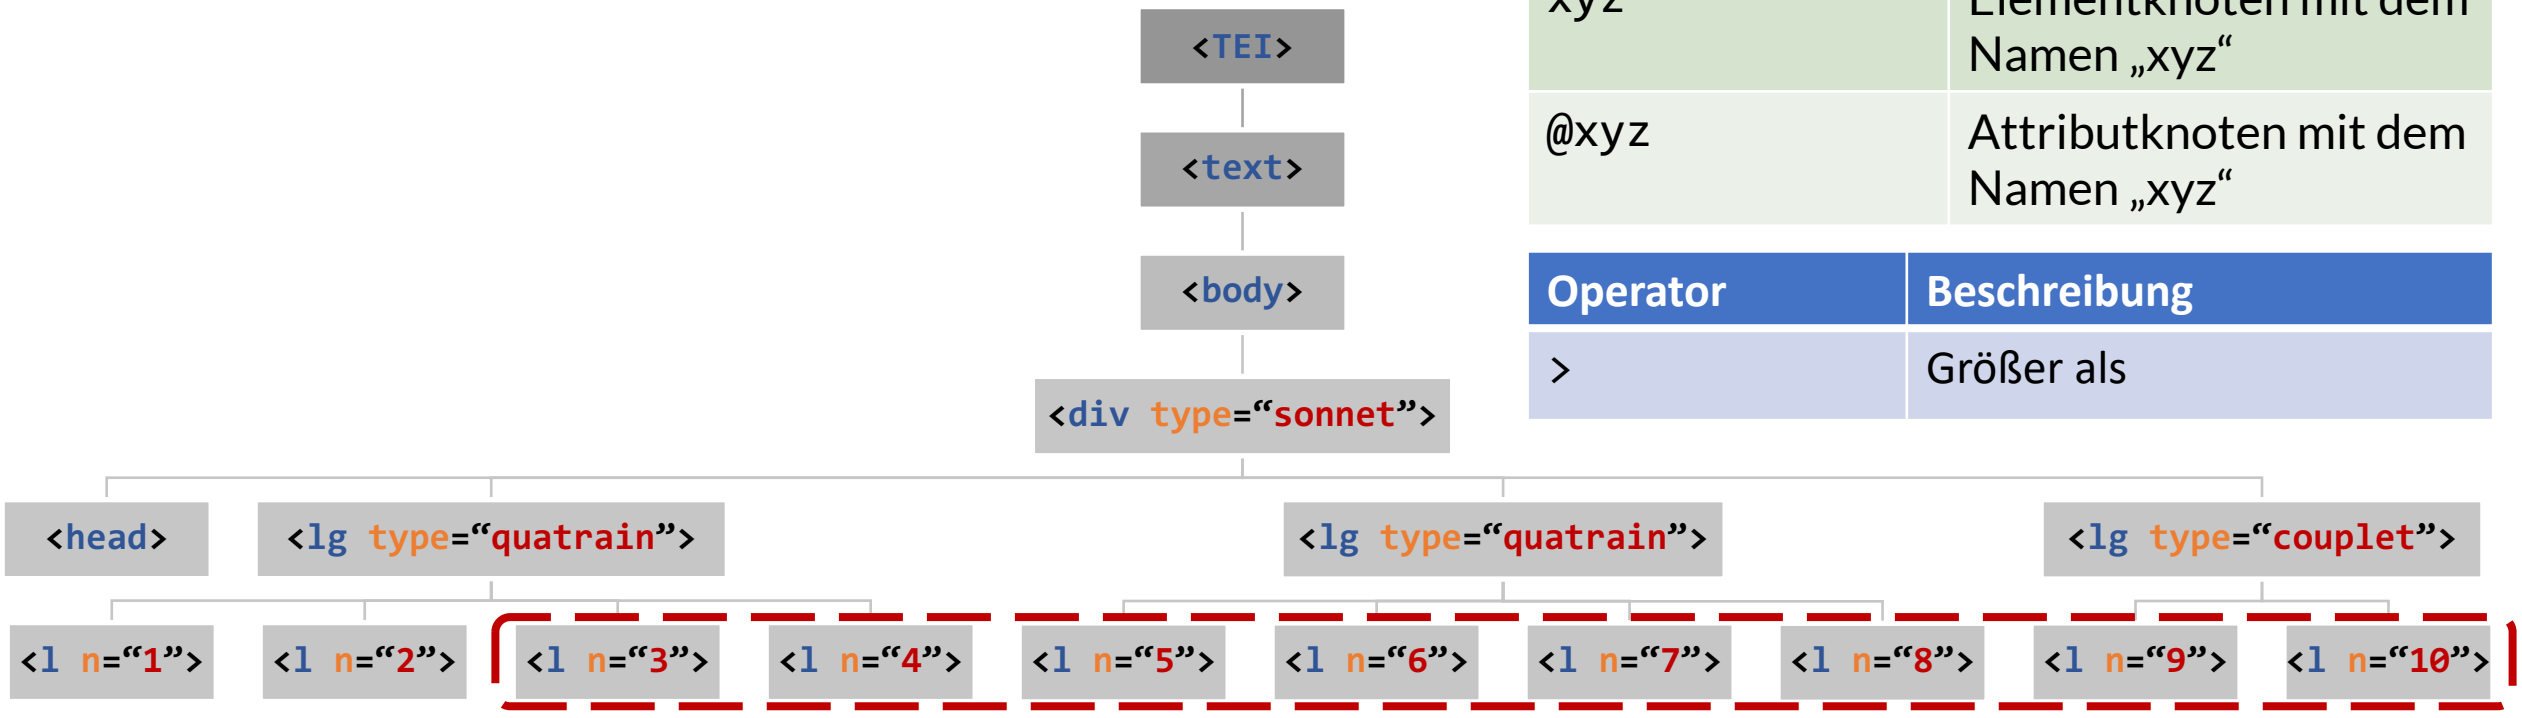

Beispiele: Ausdrücke mit Prädikaten

```
//body/div//lg[@type="quatrain"]/../@type
```

XPath-Achsen	Kurzform
child::	/
descendant-or-self::	//
parent::	..

Knotentest	Beschreibung
xyz	Elementknoten mit dem Namen „xyz“
@xyz	Attributknoten mit dem Namen „xyz“

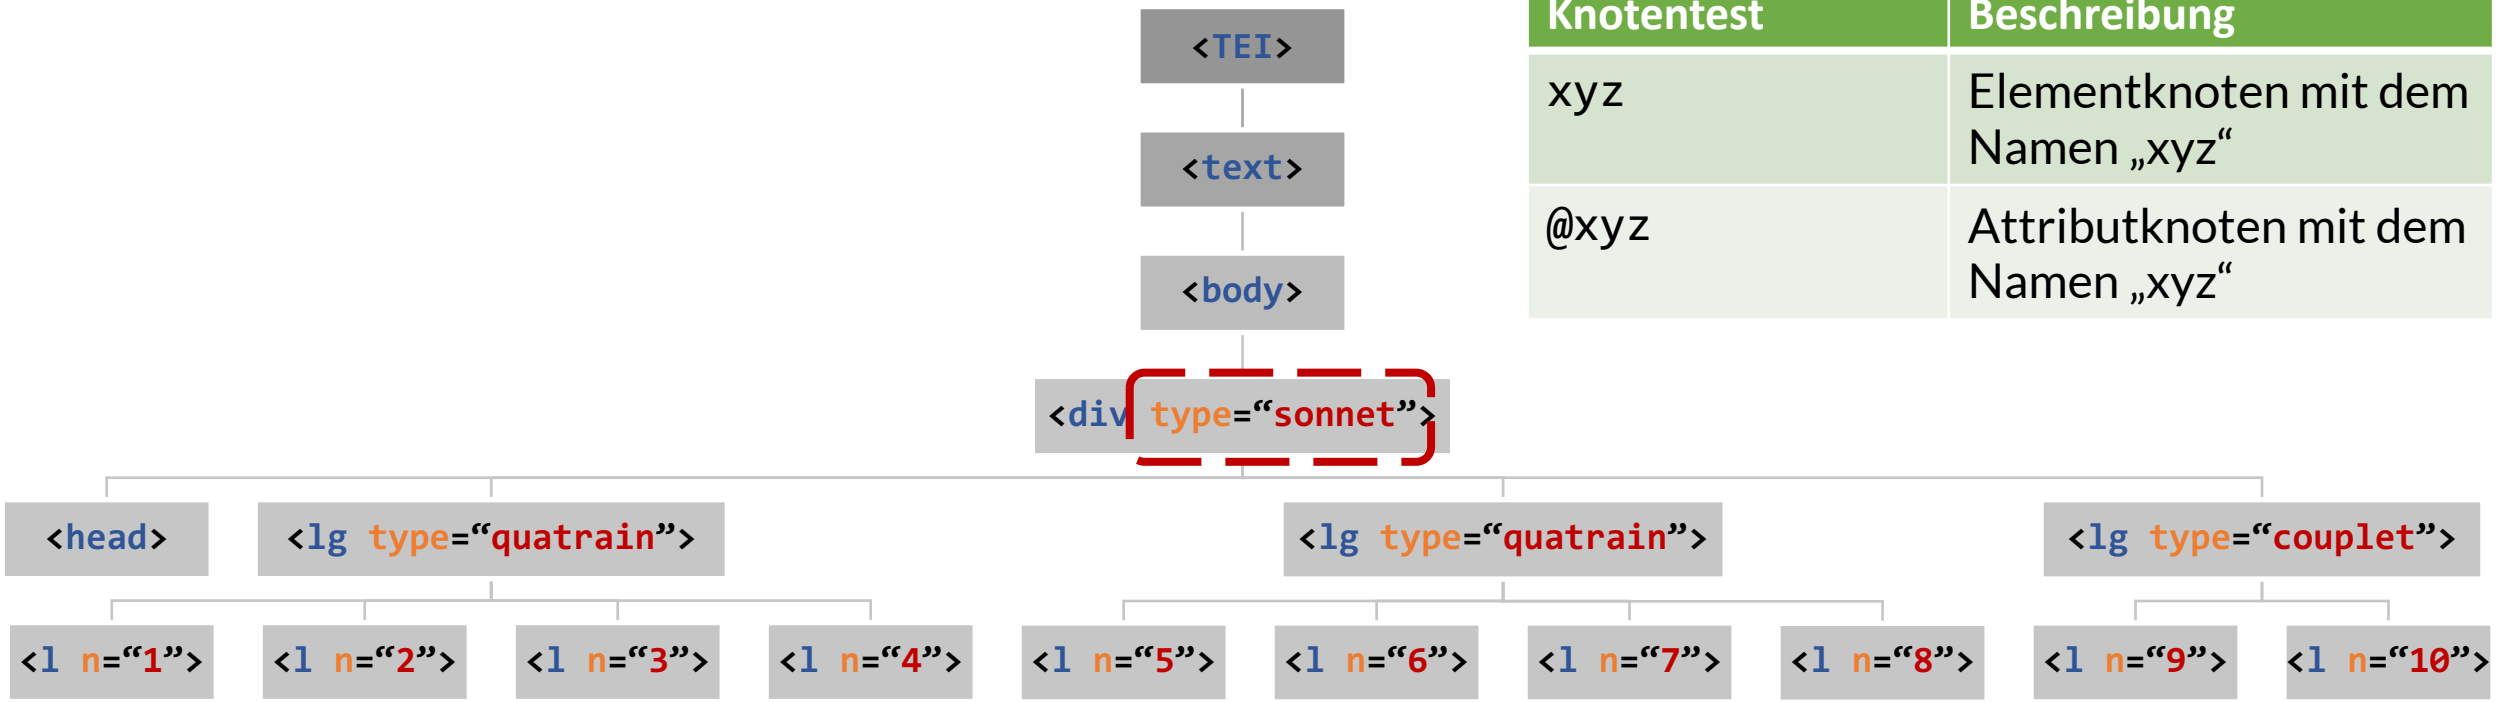

Beispiele: Ausdrücke mit Prädikaten

```
//body/div//l[ancestor::div/@type="sonnet"]
```

XPath-Achsen	Kurzform
child::	/
descendant-or-self::	//
ancestor::	

Knotentest	Beschreibung
xyz	Elementknoten mit dem Namen „xyz“
@xyz	Attributknoten mit dem Namen „xyz“

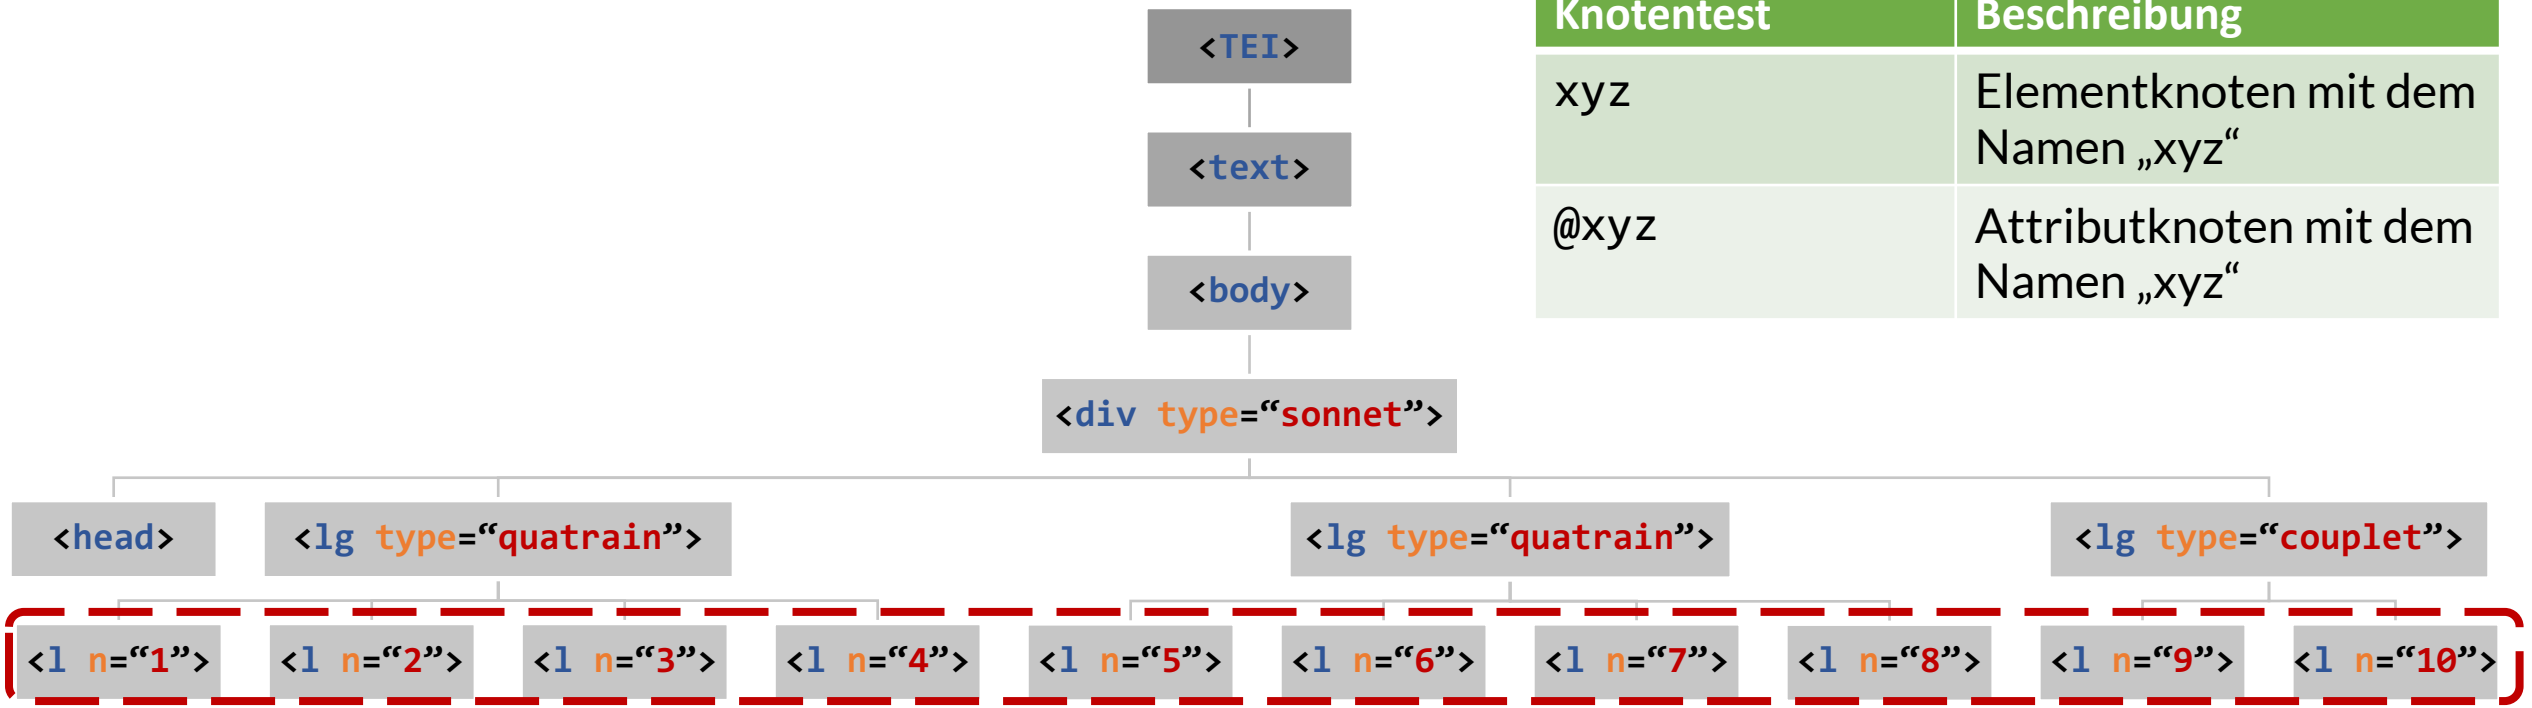

Beispiele: Ausdrücke mit Prädikaten

```
//body/div/lg[2]
```

- Sonderfall: Indizes
- Liefern Knoten an der gegebenen Position zurück
- Beginnt mit 1

XPath-Achsen	Kurzform
child::	/
descendant-or-self::	//

Knotentest	Beschreibung
xyz	Elementknoten mit dem Namen „xyz“

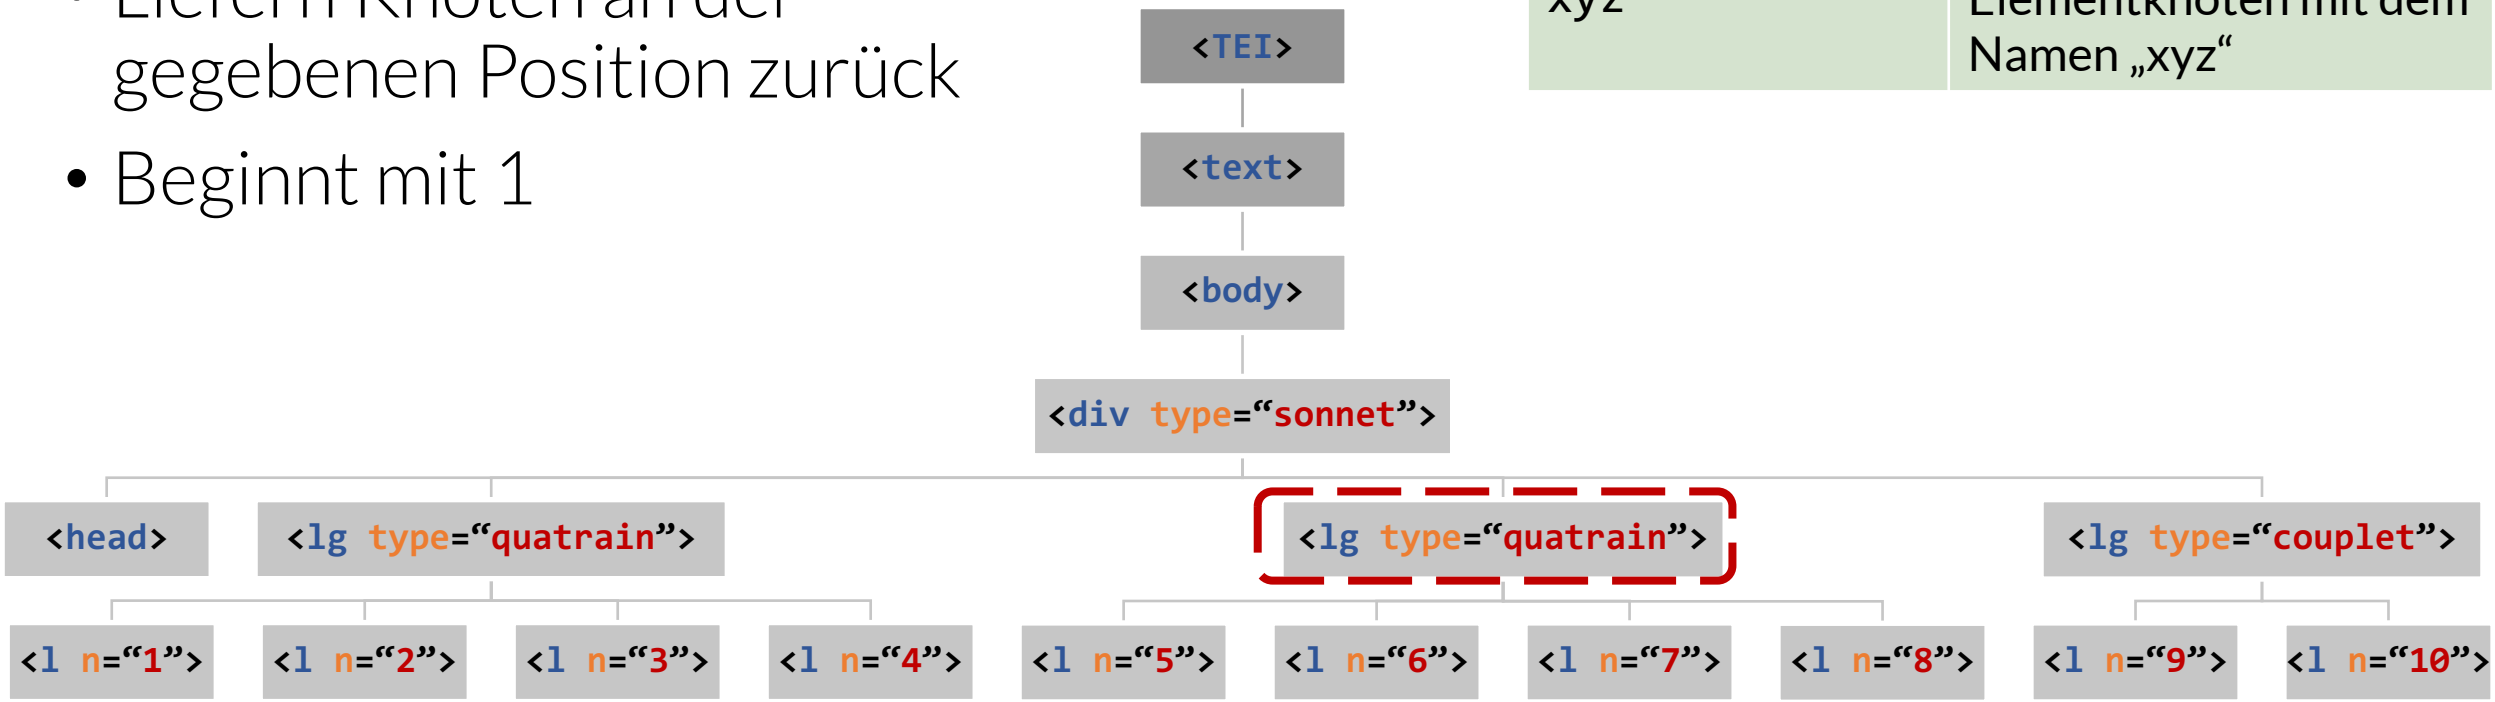

Beispiele: Ausdrücke mit Prädikaten

```
//body/div/*[2]
```

XPath-Achsen	Kurzform
child::	/
descendant-or-self::	//

Knotentest	Beschreibung
xyz	Elementknoten mit dem Namen „xyz“
*	Jeder Elementknoten

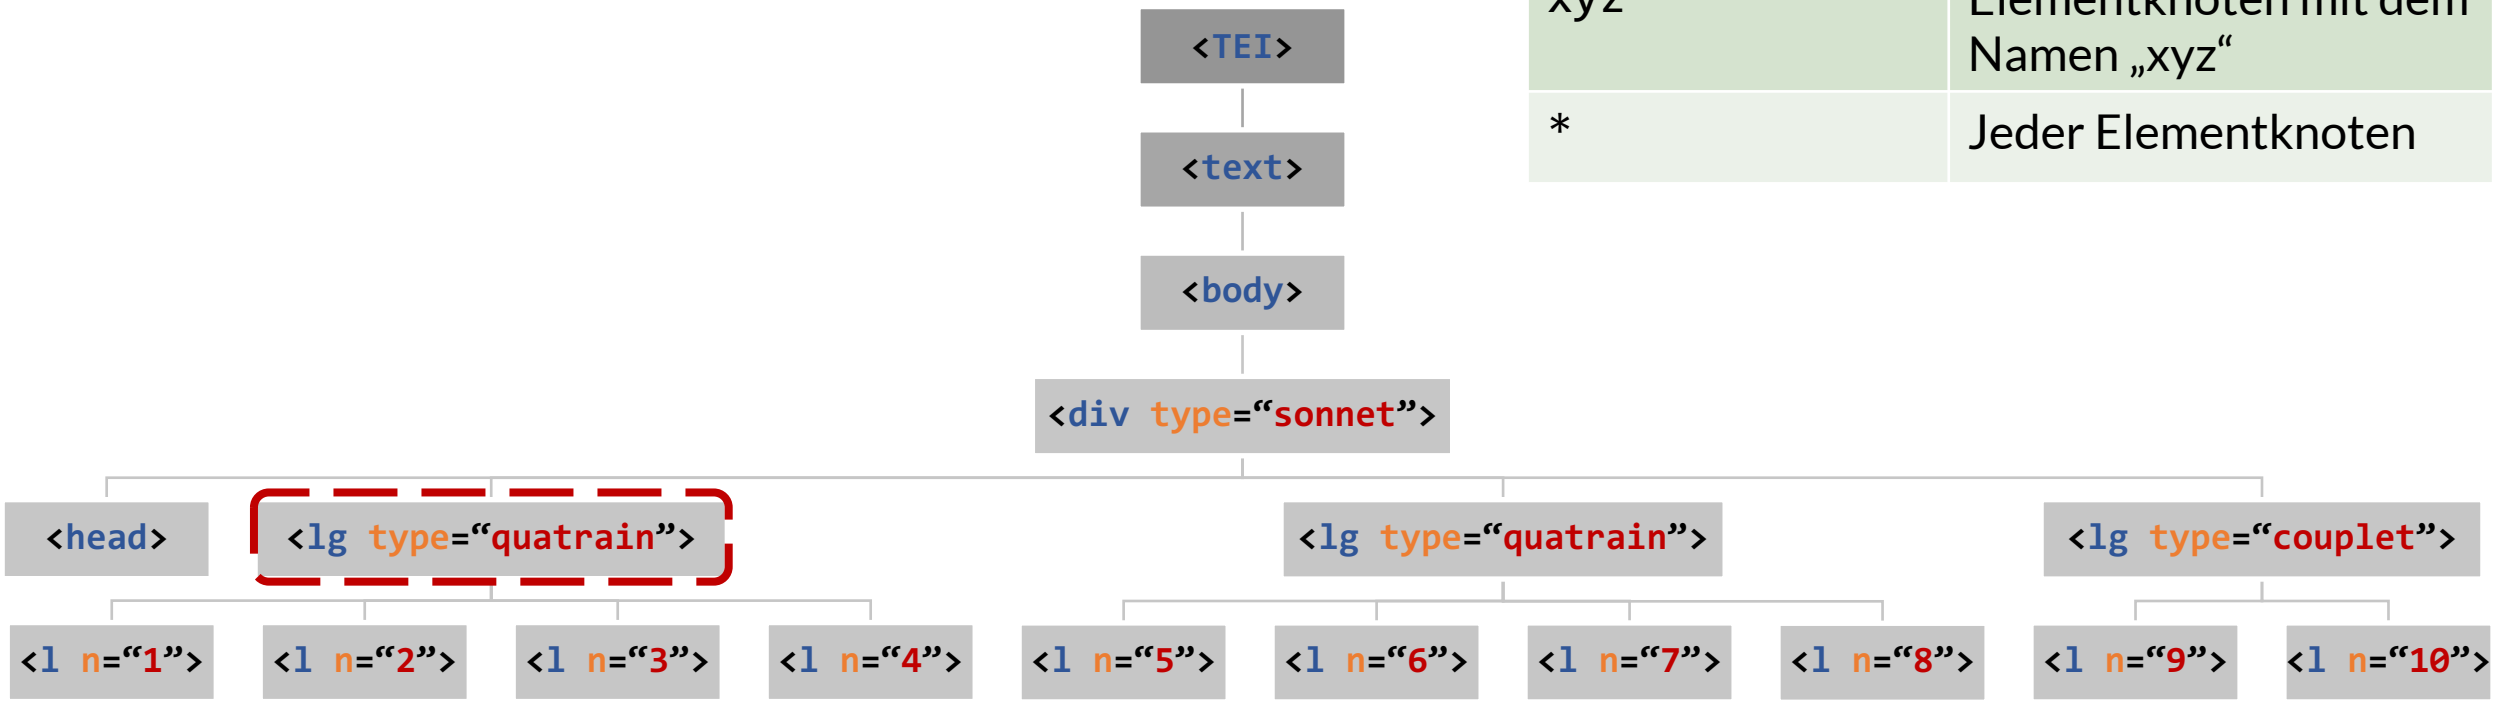

Übung: Ausdrücke mit Prädikaten

- Öffnen Sie die Datei *beispiel1.xml* in Oxygen
- Finden Sie alle Zeilen aus Vierzeiler-Versen

```
//lg[@type="quatrain"]/l
```

- Finden Sie alle Zeilen mit den Nummern 1-6

```
/l[@n <= 6]
```

- Finden Sie die dritte Zeile des dritten Verses

```
//lg[3]/l[3]
```

XPath-Achsen	Kurzform
`child::`	`/`
`descendant-or-self::`	`//`

Knotentest	Beschreibung
`xyz`	Elementknoten mit dem Namen „xyz“
`@xyz`	Attributknoten mit dem Namen „xyz“

Operator	Beschreibung
`=`	Gleichheit
`gt` oder `>` `ge` oder `>=`	Größer als Größer als oder gleich

XPath-Syntax: Funktionen

```
funktionsname(argument1, argument2)
```

- Anstelle des Knotentests oder als Teil des Prädikats
- Argumente können Knoten(sequenzen) oder Werte sein
- Verlangen unterschiedliche Arten und Anzahlen von Argumenten
- Funktionen „tun“ verschiedenes und liefern unterschiedliche Ergebnisse zurück

```
//p/count()

contains(//titleStmt/title, “Brief“)

contains(“Briefpapier“, “Brief“)
```

XPath: Rückgabearten

Sequenzen aus ein oder mehreren:

```
<persName>
  <forename>Horst</forename>
  <surname>Müller</surname>
</persName>
```

- Knoten (Elemente, Attribute, Textknoten...)
  `//lg` → (<lg>, <lg>, <lg>, <lg>)
- Zeichenketten (Strings)
  `persName/concat(forename, " ", surname)` → („Horst Müller“)
- Zahlen
  `count(//lg)` → (4)
- Wahrheitswerte (booolean: wahr / falsch)
  `contains(“Schnecke“, “ecke“)` → (wahr)

Sequenzen sind **geordnet** (haben eine bestimmte Reihenfolge) und können **Duplikate** enthalten.

Sequenzen können **leer** sein (Leere Sequenz: ( ))

Einige Funktionen I

- count(sequence)
  zählt etwas, erwartet eine Sequenz von Knoten oder Werten, liefert eine Zahl zurück
  `count(//p) → 5`

- string-length(string)
  erwartet einen String, liefert seine Länge als Zahl zurück
  `string-length(“Rindfleischettiketierungsüberwachungsaufgabenübertragungsgesetz“)→ 63`

- starts-with(string, string)
  prüft, ob ein String mit einem anderen String beginnt; liefert einen Wahrheitswert zurück
  `starts-with(“Beispiel“, “Bei“) → wahr`
  `starts-with(„Beispiel“, „Neben“) → falsch`

Einige Funktionen II

- normalize-space(string)

  Entfernt überflüssigen Whitespace aus einem String (Leerzeichen, Zeilenumbrüche, Tabulatoren...), liefert einen String zurück

  ```
  normalize-space(“  Octavie     du Rey
                    de Meynières  “)
  →"Octavie du Rey de Meynières“
  ```

- lower-case(string)

  Wandelt einen String in Kleinbuchstaben um

  ```
  lower-case(“BeIsPiEl“) → „beispiel“
  ```

- not(boolean)

  Dreht den Wahrheitswert um

  ```
  not(contains(“beispiel“, “ö“)) → wahr
  ```

Einige Funktionen III

- distinct-values(sequence of values)

  Filtert Duplikate aus einer Sequenz, liefert eine Sequenz zurück

  `distinct-values((“a“, “b“, “a“, “c“)) → (“a“, “b“, “c“)`

- string-join(sequence of strings, string)

  Verkettet eine Sequenz von Strings, fügt einen String dazwischen ein, liefert einen String zurück

  `string-join((“a“, “b“, “c“), “;“) -> „a;b;c“`

- concat(string, string, string...)

  Verkettet eine beliebige Anzahl an Strings

  `concat(“a“, “b“, “c“) -> „abc“`

- max(sequence of numbers)

  ermittelt die höchste Zahl aus einer Sequenz von Zahlen, liefert eine Zahl zurück

  `max((1923, 1823, 1723, 2009, 1345)) => 2009`

Beispiele: Ausdrücke mit Funktionen

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>...</teiHeader>
 <text>
   <body>
     <div type="sonnet">
       <head>Sonnet 18</head>
       <lg type="quatrain">
         <l n="1">Shall I compare thee to a summer's day?</l>
         <l n="2">Thou art more lovely and more temperate:</l>
         <l n="3">Rough winds do shake the darling buds of May,</l>
         <l n="4">And summer's lease hath all too short a date:</l>
       </lg>
       <lg type = "couplet">
         <l n="13">So long as men can breathe or eyes can see,</l>
         <l n="14">So long lives this and this gives life to thee. </l>
       </lg>
     </div>
   </body>
 </text>
</TEI>
```

```
count(//l)
```
→ eine Zahl
→ 6

```
//lg[count(l) = 4]
```
→ eine Sequenz von lg-Elementen
→ <lg type="quatrain">

```
//l[contains(lower-case(.), "and")]
```
→ eine Sequenz von l-Elementen
→ (<l n=2]>, <l n=4>, <l n=14>)

```
//lg[@type="couplet"]/string-join(l, " ")
```
→ ein String
→ „So long as men can breathe or eyes can see, So long lives this and this gives life to thee."

```
//lg[1]/l[last()]
```
→ ein Element
→ (<l n=14>)

Übung: Ausdrücke mit Funktionen

In beispiel1.xml:

- Zählen Sie alle Verszeilen im Dokument

```
count(//l)
```

- Finden Sie alle Zeilen, die das Wort „and“ bzw „And“ enthalten

```
//l[contains(., “and“) or contains(., “And“)]
//l[contains(lower-case(.), “and“)]
```

- Verketten Sie den Text jeder Zeile im Dokument mit einem Schrägstrich (/)

```
string-join(//l, " / ")
```

- Finden Sie die letzte Zeile jedes Verses

```
//l[last()]
```

Funktion	Rückgabe
count(sequence)	Zahl: Anzahl der Elemente in der Sequenz
contains(a, b)	wahr/falsch: ist a in b enthalten
string-join(sequence, string)	String: verkette alle Elemente mit einem gegebenen String dazwischen
last()	Zahl: Position des letzten Elements der Sequenz

Weitere XPath-Sprachelemente

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>
  <fileDesc>
   <titleStmt>
    <title>Sonnets</title>
    <author>William Shakespeare</author>
   </titleStmt>
  </fileDesc>
 </teiHeader>
 <text>
  <body>
   <div type="sonnet">
    <head>Sonnet 18</head>
    <lg type="quatrain">
     <l n="1">Shall I compare thee to a summer's day?</l>
     <l n="2">Thou art more lovely and more temperate:</l>
     <l n="3">Rough winds do shake the darling buds of May,</l>
     <l n="4">And summer's lease hath all too short a date:</l>
    </lg>
   </div>
  </body>
 </text>
</TEI>
```

- Vereinigungsoperator: |

  Vereinigt zwei Knotensequenzen in ***Dokumentreihenfolge***

```
//titleStmt/title | //body//head
//body//head | //titleStmt/title
```

→ *(<title>Sonnets</title>, <head>Sonnet 18</head>)*

Weitere XPath-Sprachelemente

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>
  <fileDesc>
   <titleStmt>
    <title>Sonnets</title>
    <author>William Shakespeare</author>
   </titleStmt>
  </fileDesc>
 </teiHeader>
 <text>
  <body>
   <div type="sonnet">
    <head>Sonnet 18</head>
    <lg type="quatrain">
     <l n="1">Shall I compare...</l>
     <l n="2">Thou art more lovely... <l>
     <l n="3">Rough winds do shake... <l>
     <l n="4">And summer's lease...</l>
    </lg>
   </div>
  </body>
 </text>
</TEI>
```

- Sequenzkonstruktor: (…, …, …)

  Konstruiert Knoten-/Wertsequenzen in ***angegebener Reihenfolge***

```
(//titleStmt/title, //body//head)
(//body//head, //titleStmt/title)
(//body//head, //titleStmt/title)[1]

//div[@type="sonnet"]/(head, lg/l[4])
    → (
        <head>Sonnet 18</head>,
        <l n="4">...</l>
       )

string-join(("a", "b", "c"), ",")
    → „a, b, c“
```

Übungen

- Öffnen Sie den Korpus der Briefedition der Berliner Intellektuellen (*teiCorpus.xml*)

- Suchen Sie alle deutschsprachigen Brieftitel
  Tipp: `[lang(“de“)]` als Kurzform von `[@xml:lang=“de“]`

- (1) Suchen Sie alle an der Korrespondenz beteiligten Personen(-namen), (2) entfernen Sie Duplikate
  Tipp: `corresp` `Desc`

- **Experimentieren Sie!** (Ideen: alle erwähnten Orte, alle vorkommenen Gedichte [lg-Elemente], alle unterstrichenen Wörter)

Reguläre Ausrücke in XPath

...sind nützlich zur

- **Analyse** von Text, z. B. *Enthält ein Textknoten eine Datumsangabe?*

```
matches(text(), "\d{1,2}\.\d{1,2}\d{4,4}")
```

- **Manipulation** z.B. *normalisiere Datumsangabe 30.09.2018 zu* ***„2018-09-30“***

```
matches(text(), "\d{1,2}\.\d{1,2}\d{4,4}")
replace("30.09.2018",
        "(\d{1,2})\.(\d{1,2})\.(\d{4,4}",
        "$3-$2-$1")
```

Reguläre Ausrücke in XPath

- **Tokenisierung** – *Aufspaltung eines Strings anhand eines Trenners*

```
tokenize(“Horst   Müller“, “\s+“)
→(“Horst“, “Müller“)

reverse(tokenize(“Müller, Horst “, “,\s“))
→(“Horst“, “Müller“)
```

Reguläre Ausrücke in XPath: Übung

In *teiCorpus.xml*:

- Suchen Sie alle Absätze, die Datumsangaben der Form TT. Monat YYYY („23. März 1080“) enthalten
  - Tipp: \w → alle Wortzeichen

```
//p[matches(., "\d{1,2}\. \w+ \d{1,4}")]
```

DARIAH-Geobrowser

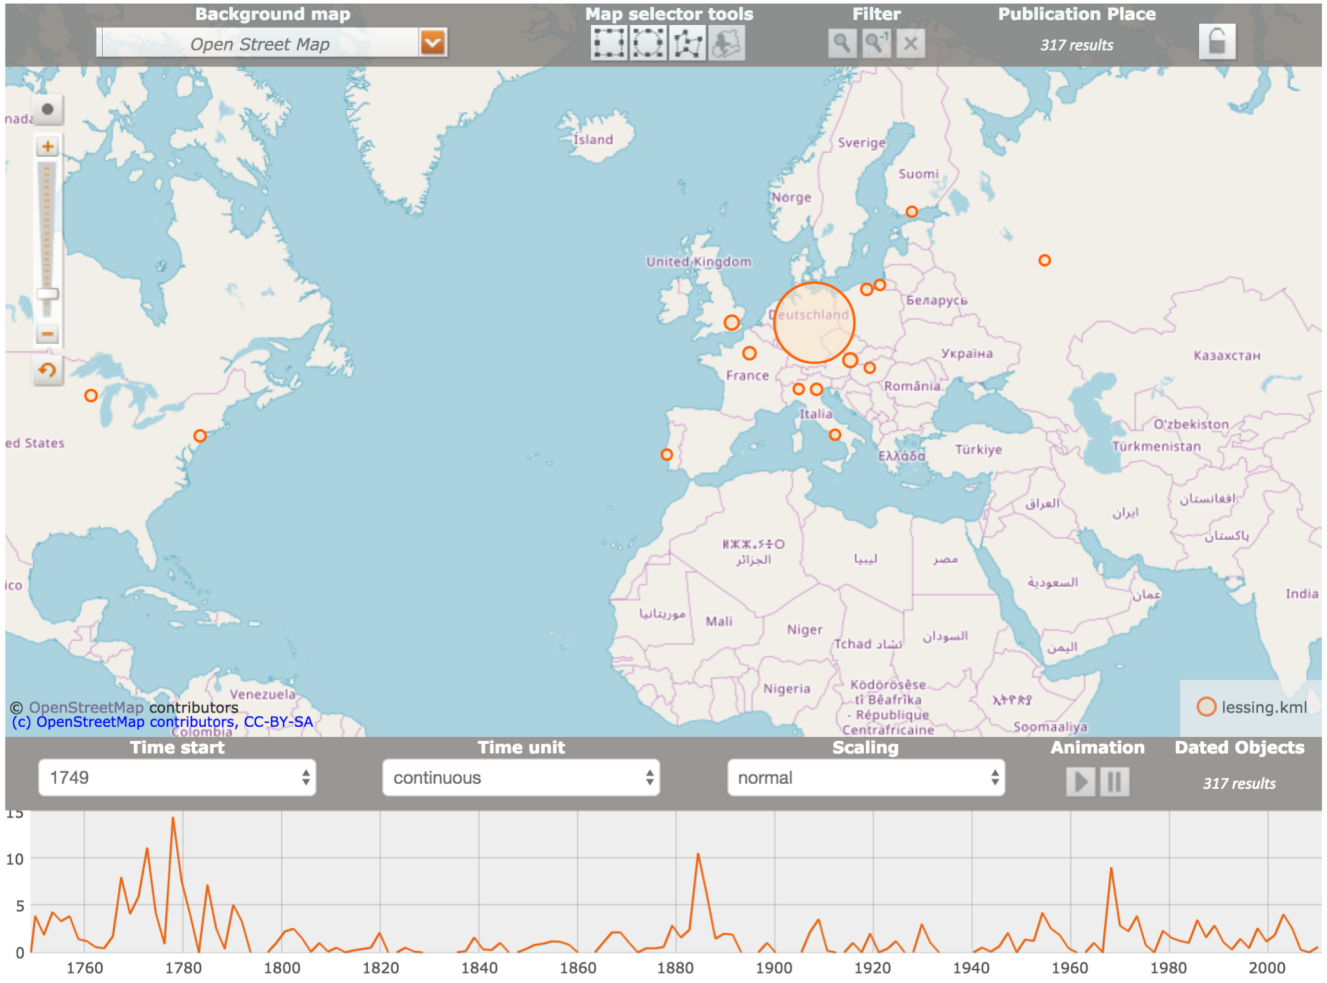

Laden Sie folgende Dateien aus dem Google Drive herunter (Ordner: geobrowser)

- geodaten2csv_basis.xsl
- Ortsindex.xml
- Universal-Kirchenzeitung - Nachrichten aus der Israelitschen Abteilung.csv

https://geobrowser.de.dariah.eu/

Aufgabe für diese Sitzung

- Die Ortsangaben mit Geokoordinaten aus dem Berlin-Corpus im Geobrowser anzeigen lassen

- Dafür müssen wir:
  - Verstehen, welche Art von Daten der Geobrowser benötigt
  - Verstehen, wie die Daten im Ortsindex des Corpus vorliegen
  - Ein XSL-Stylesheet erstellen, welches die Daten in das benötigte Format transformiert

CSV

- Der Geobrowser möchte **CSV-Daten** in einem bestimmten Format haben
- CSV: **Comma Separated Values** (Klartext-Tabellenformat)

```
Nachname, Vorname, Telefonnummer
Fischer, Franz, 0221 470 4056
Sahle, Patrick, 0221 470 3894
Dängeli, Peter, 0221 470 4055
```

CSV: String-Qualifier

- Problem: Was ist, wenn der Inhalt eines Feldes das Trennzeichen (,) enthält?

```
Nachname, Vorname, Telefonnummer, Adresse
Fischer, Franz, 0221 470 4056, Universitätsstraße 22, 50931 Köln
Sahle, Patrick, 0221 470 3894, Meister-Eckehart-Straße 22, 50931 Köln
Dängeli, Peter, 0221 470 4055, Universitätsstraße 22, 50931 Köln
```

- Lösung: Einpacken der Werte in Redezeichen

```
"Nachname", "Vorname", "Telefonnummer", "Adresse"
"Fischer", "Franz", "0221 470 4056", "Universitätsstraße 22, 50931 Köln"
"Sahle", "Patrick", "0221 470 3894", "Meister-Eckehart-Straße 22, 50931 Köln"
"Dängeli", "Peter", "0221 470 4055", "Universitätsstraße 22", "50931 Köln"
```

CSV: Escaping

- Problem: Was ist, wenn der Inhalt eines Feldes Redezeichen enthält?

```
"Nachname", "Vorname", "Telefonnummer", "Addresse"
"Fischer", "Franz "Fröhlich"", "0221 470 4056", "Universitätsstraße 22, 50931 Köln"
"Sahle", "Patrick", "0221 470 3894", "Meister-Eckehart-Straße 22, 50931 Köln"
"Dängeli", "Peter", "0221 470 4055", "Universitätsstraße 22", "50931 Köln"
```

- Lösung: „Escaping“ durch doppelte Redezeichen

```
"Nachname", "Vorname", "Telefonnummer", "Addresse"
"Fischer", "Franz ""Fröhlich""", "0221 470 4056", "Universitätsstraße 22, 50931 Köln"
"Sahle", "Patrick", "0221 470 3894", "Meister-Eckehart-Straße 22, 50931 Köln"
"Dängeli", "Peter", "0221 470 4055", "Universitätsstraße 22", "50931 Köln"
```

Geobrowser-CSV: Beispiel

```
"Name","Address","Description","Longitude","Latitude","TimeStamp","TimeSpan:begin","TimeSpan:end","GettyID",""
"Altona","Altona","Steinheim’s Portrait","10.4167","51.8","1837-06-29","","","7005628",""
"Alzey","Alzey","Einweihung einer Thorarolle","8.1167","49.75","1837-02-16","","","7005992",""
"Augsburg","Augsburg","Corresp.-Ber., die relig. Angelegenheiten der Israeliten betr.","10.9","48.35","1837-04-13","","","7004324",""
"Berlin","Berlin","Erbauung zweier christl. Kirchen von israel. Freigebigkeit","13.4167","52.5333","1837-02-23","","","7003712",""
```

Ortsindex → Geobrowser-CSV: Vorbereitung

- Schritt 1: Wie sieht unser Zielformat aus? Was brauchen wir?

  → Eine CSV-Datei mit den Spalten Name, Address, Description, Longitude, Latitude

  (für unsere Zwecke: Name = Address, Description bleibt leer)

- Schritt 2: Wie sehen unsere Daten aus? Was haben wir?

  Das sehen wir uns mal genauer an... → Ortsindex.xml
  (müssen wir Strings in Redezeichen einpacken? Sind die Geokoordinaten einheitlich formatiert?)

Ortsindex → Geobrowser-CSV

Nützliche Funktionen	
`string-join(sequence, string)`	verkette alle Elemente mit einem gegebenen String dazwischen
`tokenize(string, regex)`	Spaltet einen String in mehrere auf
`matches(string, regex)`	Überprüft, ob ein regulärer Ausdruck auf einen String passt
`reverse(sequence)` `reverse(("a“, “b“, “c“)) → ((“c“, “b“, “a“))`	Dreht eine Sequenz um

Ziel: eine Kopfzeile mit den Spaltennamen
+ für jeden Ort eine Zeile mit 2 x Ortsnamen sowie Longitude und Latitude

```
"Name","Address","Description","Longitude","Latitude"
"Dresden","Dresden","","13.73836","51.049259"
"Leipzig","Leipzig","","12.37475","51.340333“
...
```

Ortsindex → Geobrowser-CSV

- Öffnen Sie das Grundgerüst für die XSL-Transformation: *geodaten2csv_basis.xsl*
- Schritt 1: Generieren Sie die Kopfzeile der CSV-Datei (+ Zeilenumbruch)

```
"Name","Address","Description","Longitude","Latitude"
```

```
<xsl:template match="/">
    <xsl:text>"Name","Address","Description","Longitude","Latitude"</xsl:text>
    <xsl:value-of select="$newline" />
</xsl:template>
```

Ortsindex → Geobrowser-CSV

- Schritt 2: Generieren Sie für jedes Place-Element eine Zeile, die den (deutschsprachigen) Namen des Ortes enthält

```
<xsl:for-each select=".//tei:place">
  <xsl:value-of select="(./tei:placeName[lang('de')], ./tei:placeName)[1]" />
  <xsl:value-of select="$newline" />
</xsl:for-each>
```

- Schritt 3: Formatieren Sie die Zeilen richtig – Ortsnamen zwei mal hintereinander, mit Redezeichen umschlossen, mit Komma getrennt

```
"Dresden","Dresden"
"Leipzig","Leipzig"
```

```
<xsl:for-each select=".//tei:place">
   <xsl:text>&quot;</xsl:text>
   <xsl:value-of select="(./tei:placeName[lang('de')], ./tei:placeName)[1]" />
   <xsl:value-of select="$separator" />
   <xsl:value-of select="(./tei:placeName[lang('de')], ./tei:placeName)[1]" />
   <xsl:text>&quot;</xsl:text>
   <xsl:value-of select="$newline" />
</xsl:for-each>
```

- Schritt 4: Als dritte CSV-Spalte benötigen wir einen leeren String („description“) – fügen Sie an der Richtigen Stelle zwei CSV-Trenner hintereinander ein

```
<xsl:for-each select=".//tei:place[matches(tei:location/tei:geo, '-?\d+\.?\d*°?,? -?\d\.?\d*')]">
        <xsl:text>&quot;</xsl:text>
        <xsl:value-of select="(./tei:placeName[lang('de')], ./tei:placeName)[1]" />
        <xsl:value-of select="$separator" />
        <xsl:value-of select="(./tei:placeName[lang('de')], ./tei:placeName)[1]" />

        <xsl:value-of select="$separator" />
        <xsl:value-of select="$separator" />

        <xsl:text>&quot;</xsl:text>
</xsl:for-each>
```

- Schritt 5: Schränken Sie die Auswahl der Place-Elemente auf solche ein, die gültige Koordinaten haben (deren `tei:location/teo:geo`-Elemente auf den zuvor ermittelten Regulären Ausdruck passen)

```
-?\d+\.?\d*°?,?\s-?\d\.?\d*
```

Tipp: Prädikat mit matches()-Funktion

```
<xsl:for-each select=".//tei:place[matches(tei:location/tei:geo, '-?\d+\.?\d*°?,? -?\d\+.?\d*')]">
```

- Schritt 6: Schreiben Sie ein Template für `tei:geo`-Elemente, welches die Koordinaten in unser Zielformat bringt, indem es
  - Die Koordinaten in zwei Strings **aufspaltet** (Latitude und Longitude)
    denken Sie an die möglichen Trennzeichen und unseren Trenner-Regex:
    `°?,?\s`
  - Diese **umdreht** (der CSV Browser möchte erst Longitude, dann Latitude!)

    → reverse(sequence)
  - Und diese dann wieder mit unserem CSV-Trenner **zusammenfügt**!

`“50.938056 6.956944“ → 6.956944&quot;,&quot;50.938056`

```
<xsl:template match="tei:geo">
  <xsl:value-of select="string-join(reverse(tokenize(., '°?,?\s')), $separator)" />
 </xsl:template>
```

- Schritt 7: Wenden Sie das Koordinaten-Template an der richtigen Stelle an

```
<xsl:for-each select=".//tei:place[matches(tei:location/tei:geo, '-?\d+\.?\d*°?,? -?\d\.?\d*')]">
    <xsl:text>&quot;</xsl:text>
    <xsl:value-of select="(./tei:placeName[lang('de')], ./tei:placeName)[1]" />
    <xsl:value-of select="$separator" />
    <xsl:value-of select="(./tei:placeName[lang('de')], ./tei:placeName)[1]" />

    <xsl:value-of select="$separator" />
    <xsl:value-of select="$separator" />

    <xsl:apply-templates select="./tei:location/tei:geo"></xsl:apply-templates>

    <xsl:text>&quot;</xsl:text>
    <xsl:value-of select="$newline" />
</xsl:for-each>
```

Übersichten und Referenzen

Übersichten

https://www.data2type.de/xml-xslt-xslfo/xpath/referenz/

https://www.w3schools.com/xml/xsl_functions.asp

https://www.w3schools.com/xml/xpath_intro.asp

Referenzen

https://www.w3.org/TR/xpath-31/

https://www.w3.org/TR/xpath-functions-31/

Kontakt

Fragen? Gerne melden!

Marcel Schaeben
m.schaeben@uni-koeln.de

Sebastian Zimmer
sebastian.zimmer@uni-koeln.de

Cologne Center for eHumanities (CCeH) | cceh.uni-koeln.de

Mit Dank für Material und Inspiration an:
James Cummings, Ulrike Henny , Patrick Sahle, Daniel Schopper