Transformation von XML-Dokumenten

Was ist XSL – politisch?

- XSL ist eine eigene Technik.
- Zum Publizieren (Transformieren) von Dokumenten.
- Früher gab es dafür Verlage und Schriftsetzer, um gute Inhalte in gute Produkte zu verwandeln.
- Seit Word müssen wir das alles selber machen.
- Das führt in die falsche Richtung, XML/XSLT/XQuery verschärft das Problem noch.
- Jeder, der mit XML gute Inhalte erstellt sollte einen neben sich sitzen haben, der daraus gute Produkte erzielt.

Was ist XSL – technisch?

- Mehrere Komponenten:
  - XSLT → Transformations
  - XSL-FO → Formatting Objects
- Ausgabeformate von XSLT:
  - (x)HTML
  - XML → z.B. Word, TEI, RDF, SVG
  - Text → z.B. LaTeX (→ PDF), RTF, MARC
- Ausgabeformat von XSL-FO:
  - XML → PostScript → PDF

XSLT-Verarbeitung

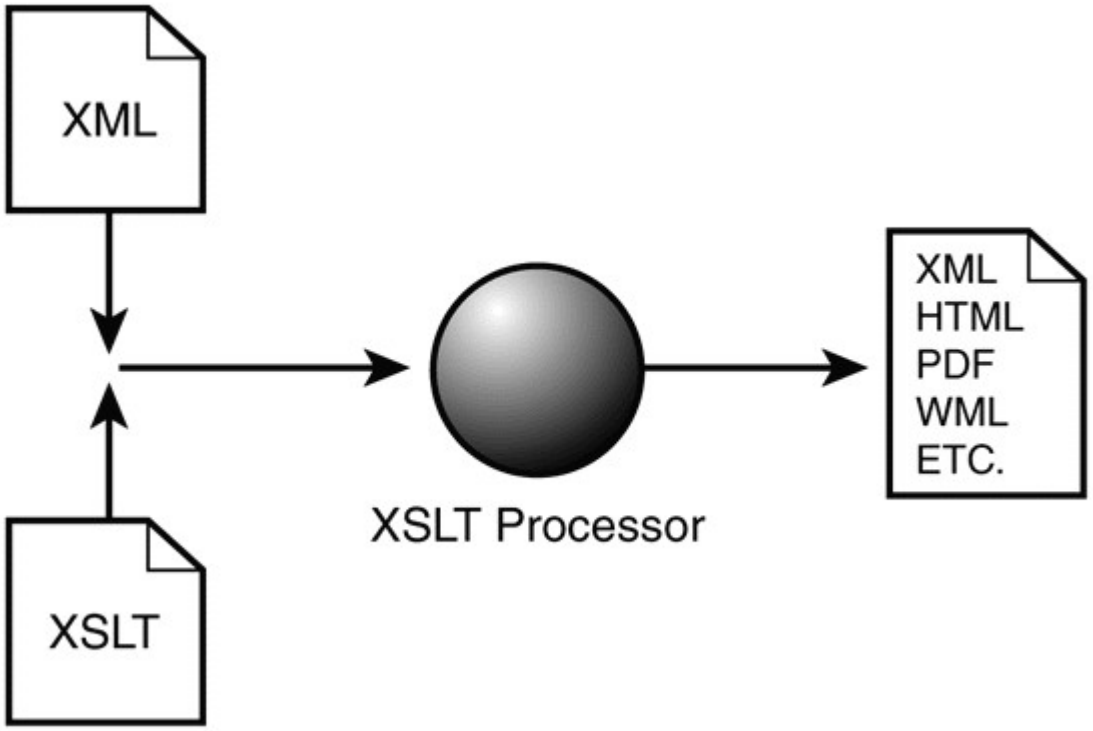

XML: Vor- und Nachteile

- Vorteil: Die Trennung von Struktur, Inhalt und Aussehen.
- Nachteil: Die Trennung von Struktur, Inhalt und Aussehen.

- Problem: Wenn ein Ergebnis ausgegeben werden soll, muss man die Zielsprache auch kennen!
  - HTML, CSS, (JavaScript)

- Problem: Alles, was ein Ausgabedokument „leisten“ soll, muss in der Kodierung vorhanden sein.
  - z.B. Register, Verknüpfungen, Formatierungen

Strukturen im XML

- Abschnitte, Absätze (Unterscheidung physikalische, inhaltliche Strukturen, phrase-level
- Listen (Aufzählung, Bibliographie, etc), Tabellen
- Bilder
- textuelle Eingriffe (Ersetzung, Abkürzung)
- Seitenumbrüche
- Fußnoten, Referenzen
- Register
- Sonderzeichen / Unicode
- weitere?

Strukturen im HTML

- Abschnitte, Absätze, Überschriften
- Listen (Aufzählung, Bibliographie, etc), Tabellen
- Bilder
- Sonderzeichen / Unicode
- Formatierungen (CSS)
- weitere?

Ein Transformationsergebnis: HTML

- Die wichtigsten HTML-Elemente
  - html, head, body
  - div, p, h1-6
  - span, pre
  - ul, ol, li
  - table, tr, td
- CSS (Cascading Stylesheets)
  - font-weight:bold
  - font-size:smaller
  - font-style:italic
- http://de.selfhtml.org

XSL (eXtensible Stylesheet Language)

- Der Prozessor traversiert den Baum!
  - Immer, wenn ein neues Ereignis wahrgenommen wird (neues Element, Attribut, Text), wird in der XSL-Datei nachgeschaut, ob eine Regel angewendet werden muss.

- Woher weiß der Prozessor, wann er was machen soll?

  → **XPath**

  → <xsl:template match=“”/>

XPath

- Technologie zur Adressierung von Knoten
- Enthält nützliche Funktionen
- Achsen-basierte Navigation durch die Hierarchieebenen

Ohne XPath ist die Abfrage und Verarbeitung von XML-Dokumenten unmöglich!

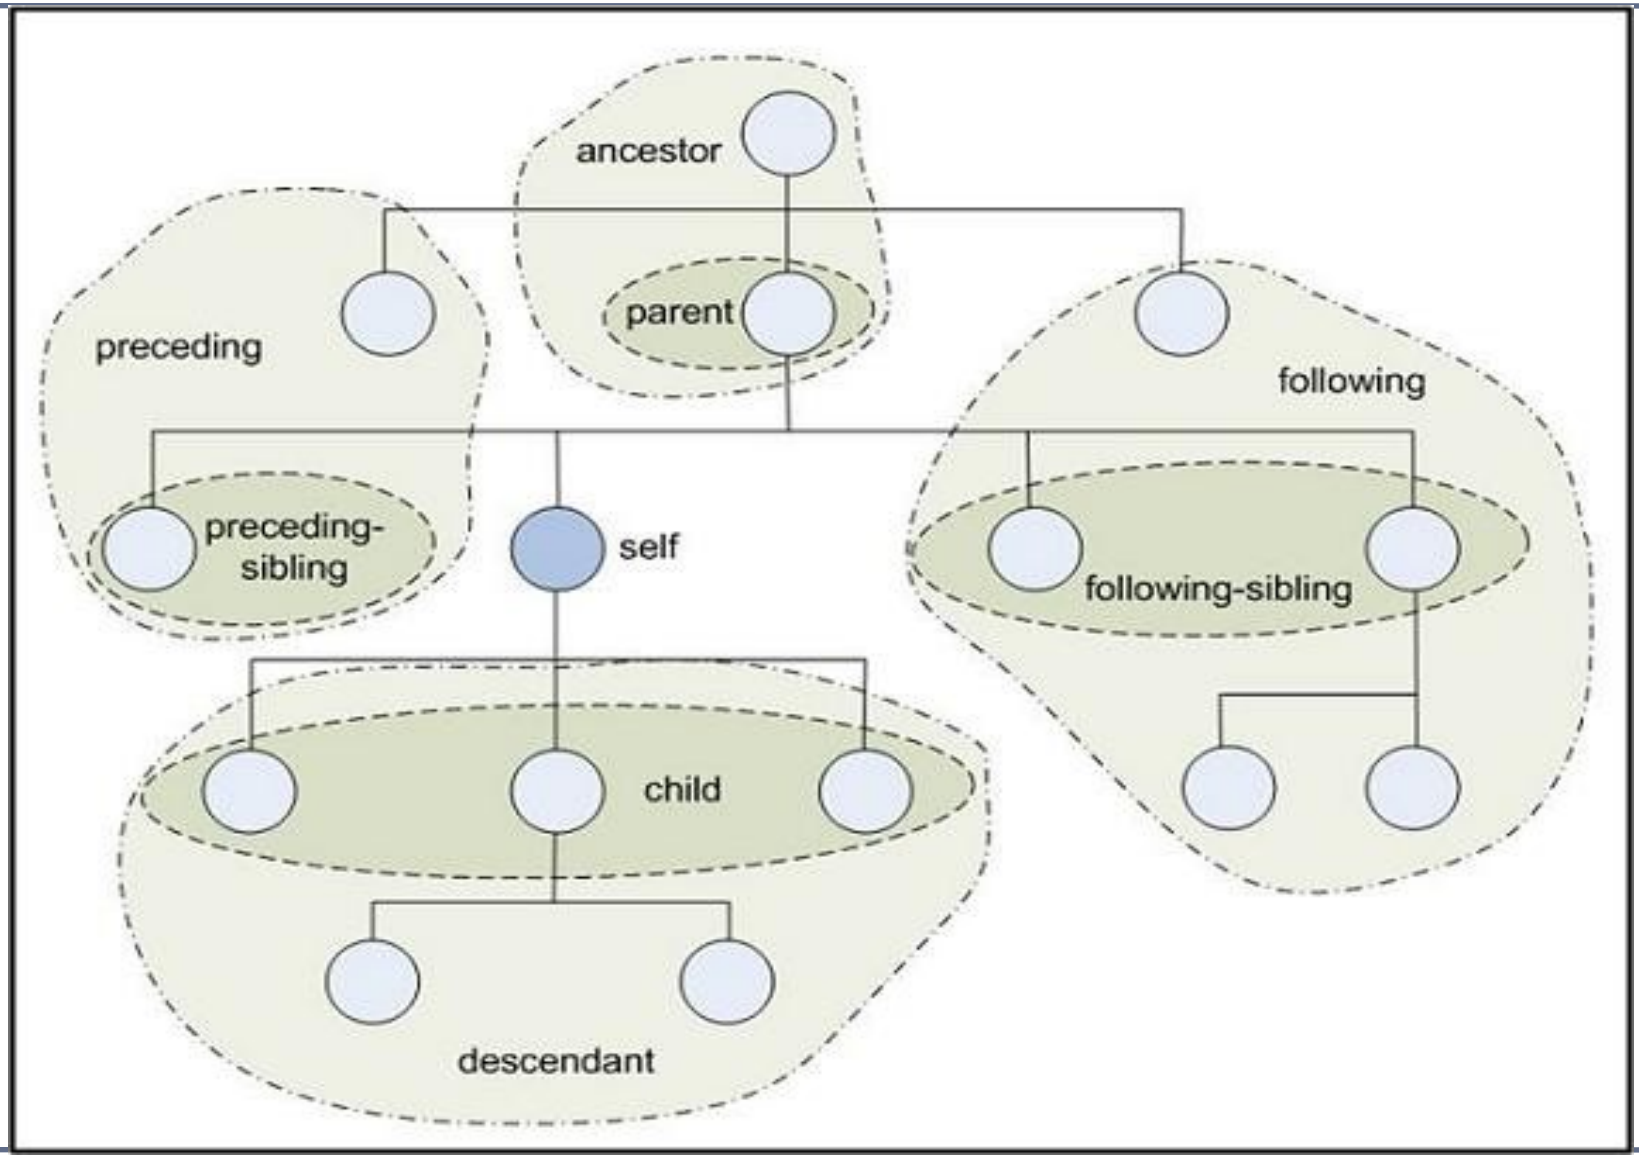
ancestor
parent
preceding
following
preceding-sibling
self
following-sibling
child
descendant

XPath Knotentypen

7 Knotentypen

- Dokument- und Elementknoten <person>…</person>
- Text- und Attributknoten <el att=„value“>text</el>
- Namensraumknoten <tei:lb/>
- Processing-Instruction-Knoten <? … ?>
- Kommentarknoten <!-- … -->

XPath Notation

- Nach dem Prinzip: **achse::knotentest([prädikat])**
  - /
  - /child::persName
  - /descendant::persName
  - /parent::*
  - /child::person/attribute::role
  - /self::TEI/child::*

XPath verkürzte Notation

- Nach dem Prinzip: **achse::knotentest([prädikat])**
  - / → /
  - /child::persName → /persName
  - /descendant::persName → //persName
  - /parent::* → ..
  - /child::person/attribute::role → /person/@role
  - /self::TEI/child::* → ./*

XPath Prädikate

- Bedingungen, die Submengen definieren
  - //person[@role = “member“]
  - /persName[surname = “müller“]
  - /persName[surname != “müller“]
  - //person[1]
  - //person[last()]/persName
  - //person[position() > 5]

XPath Funktionen

- Dienen zur weiteren Verarbeitung und Adressierung von Knotenmengen

- 4 Gruppen von Funktionen
  - **Knotenmengenfunktionen**
  - **Zeichenkettenfunktionen**
  - Logische (boolsche) Funktionen
  - Numerische Funktionen

XPath Funktionen

- Knotenmengen
  - last(), position(), current(), count(), …
- Zeichenketten
  - concat()
  - contains(), matches()
  - starts-with(), ends-with()
  - substring(), substring-before(), substring-after()
  - translate()

xsl:stylesheet

```
<xsl:stylesheet version="1.0"
      xmlns:xsl="http://www.w3.org/1999/XSL/Transform">

  … Anweisungen hierher ...

    </xsl:stylesheet>
```

- Wichtig: TEI-Dateien müssen mit TEI-Namespace verarbeitet werden!

```
<xsl:stylesheet version="1.0"
      xmlns:tei="http://www.tei-c.org/ns/1.0"
      xmlns:xsl="http://www.w3.org/1999/XSL/Transform">
    </xsl:stylesheet>
```

XSLT Beispiel

- XML: <message>Hallo Welt!</message>
- XSLT:

```
<xsl:stylesheet version="1.0"
      xmlns:xsl="http://www.w3.org/1999/XSL/Transform">
      <xsl:template match="/">
        <html><body>
          <h1><xsl:value-of select="message"/></h1>
        </body></html>
      </xsl:template>
    </xsl:stylesheet>
```

- Der HTML-Namespace wird als default angenommen!

Das Grundgerüst: Templates

```
<xsl:template match=" xpath-ausdruck ">
        … Anweisungen …
    </xsl:template>
```

- Schablone als Anweisung, an welcher Stelle im XML-Dokument (match="XPath") etwas gemacht werden soll

Die „push“-Methode

<xsl:apply-templates select="xpath-ausdruck"/>

- Anweisung, dass die Verarbeitung weiterer Templates fortgeführt werden soll.
- Optional kann die zu verarbeitende **Knotenmenge** über das @select per XPath bestimmt werden.

Beispiel:

```
<xsl:template match="/">
    <xsl:apply-templates/>
</xsl:template>
```

Die „pull“-Methode

<xsl:call-templates name=" name-eines-templates "/>

- Templates können gezielt aufgerufen werden.
- Anwendung: Registerbildung

Beispiel:

```
<xsl:template match="/">
  <xsl:call-template name=" irgendein-name ">
</xsl:template>
<xsl:template name="irgendein-name ">
    … macht was …
</xsl:template>
```

Ausgabe von Text

<xsl:value-of select=" *xpath-ausdruck*"/>

- Wählt den **Wert** eines XPath-Ausdrucks, also **Text** eines Elements oder Attributs und fügt diesen in die Ausgabe ein.
- <h1> <xsl:value-of select="message"/> </h1>

<xsl:text> Schreibe diesen Text … </xsl:text>

Schleifen

```
<xsl:for-each select=" xpath-ausdruck ">
    …
</xsl:for-each>
```

- Beispiel: Wähle jeden Text (//msItem) und generiere eine Aufzählung (<ul>) der Titel (title):

```
<ul>
  <xsl:for-each select="//msItem">
    <li>  <xsl:value-of select="title"/>  </li>
  </xsl:for-each>
</ul>
```

Bedingungen I

<xsl:if test=" *xpath-ausdruck* "> … </xsl:if>

- Führt Anweisungen nur aus, wenn die Bedingung in @test erfüllt ist.

Beispiel:

```
<xsl:for-each select="//book">
  <xsl:if  test=" author = 'Cassiodor' ">
    <li><xsl:value-of select="title"/></li>
  </xsl:if>
</xsl:for-each>
```

Bedingungen II

```
<xsl:choose>
  <xsl:when test=" xpath-ausdruck "> … </xsl:when>
  <xsl:otherwise></xsl:otherwise>
</xsl:choose>
```

- Unterscheidet mehrere Fälle, in denen Anweisungen nur ausgeführt werden, wenn die Bedingung in @test erfüllt ist. Ansonsten werden die Anweisungen des xsl:otherwise ausgeführt.

Sortieren

<xsl:sort select=" *xpath-ausdruck* "/>

- Sortiert die Elemente einer Schleife (nach dem ausgewählten Kriterium)
- Wird immer innerhalb von <xsl:for-each> oder <xsl:apply-templates> verwendet

Beispiel:

```
<ul>
  <xsl:for-each select="//msItem">
    <xsl:sort select="author"/>
    <li> <xsl:value-of select="title"/>
      <xsl:text> von </xsl:text>
      <xsl:value-of select="author"/> </li>
  </xsl:for-each>
</ul>
```

Kopieren

<xsl:copy/>

- Kopiert den aktuellen Knoten inklusive Namespace
- Kopiert keine Attributte, Inhalte, Kindknoten

<xsl:copy-of select="*xpath-ausdruck*"/>

- Kopiert den ausgewählten Knoten inklusive aller Kindknoten und Attribute

Variablen / Parameter

<xsl:variable name="“ />

- wird einmalig festgelegt

<xsl:param name="″/>

- kann „unterwegs“ verändert werden